Nowcasting del crecimiento económico en Colombia mediante modelos bayesianos de frecuencia mixta

Juan Diego Moreno Sánchez [1] Zeneth Olivero Tapia [2]
Jacobo Campo Robledo [1,2]

[1]Universidad Externado de Colombia

[2]Universidad Católica de Colombia

Julio 14 de 2026

Contenido

1. Introducción - Problema
2. Marco Teórico y Revisión de Bibliografía
3. Datos y Metodología
   - Datos
   - Metodología
4. Estimaciones y Resultados
5. Consideraciones finales

Contenido

1. Introducción - Problema
2. Marco Teórico y Revisión de Bibliografía
3. Datos y Metodología
   - Datos
   - Metodología
4. Estimaciones y Resultados
5. Consideraciones finales

Contenido

1. Introducción - Problema
2. Marco Teórico y Revisión de Bibliografía
3. Datos y Metodología
   - Datos
   - Metodología
4. Estimaciones y Resultados
5. Consideraciones finales

Contenido

1. Introducción - Problema
2. Marco Teórico y Revisión de Bibliografía
3. Datos y Metodología
   - Datos
   - Metodología
4. Estimaciones y Resultados
5. Consideraciones finales

Contenido

1. Introducción - Problema
2. Marco Teórico y Revisión de Bibliografía
3. Datos y Metodología
   - Datos
   - Metodología
4. Estimaciones y Resultados
5. Consideraciones finales

Contenido

1. Introducción - Problema
2. Marco Teórico y Revisión de Bibliografía
3. Datos y Metodología
   - Datos
   - Metodología
4. Estimaciones y Resultados
5. Consideraciones finales

Contenido

1. Introducción - Problema
2. Marco Teórico y Revisión de Bibliografía
3. Datos y Metodología
   - Datos
   - Metodología
4. Estimaciones y Resultados
5. Consideraciones finales

Introducción - Problema

El Problema

- El PIB es el indicador más importante para monitorear el ciclo económico, pero en Colombia (como en la mayoría de países) se publica trimestralmente y con rezago (DANE publica 45 días después del cierre del trimestre).
- Entre el cierre de un trimestre y la publicación oficial, los hacedores de política, analistas de mercado y el sector privado deben tomar decisiones sin saber aún qué pasó con la economía.

Introducción - Problema

El Problema

- El PIB es el indicador más importante para monitorear el ciclo económico, pero en Colombia (como en la mayoría de países) se publica trimestralmente y con rezago (DANE publica 45 días después del cierre del trimestre).
- Entre el cierre de un trimestre y la publicación oficial, los hacedores de política, analistas de mercado y el sector privado deben tomar decisiones sin saber aún qué pasó con la economía.
- En contraste, existe un conjunto amplio de indicadores de alta frecuencia (mensual) disponibles casi en tiempo real: ISE, producción manufacturera, ventas del comercio, inflación, tasa de cambio, tasa de política monetaria, precio del petróleo.

Introducción - Problema

El Problema

- El PIB es el indicador más importante para monitorear el ciclo económico, pero en Colombia (como en la mayoría de países) se publica trimestralmente y con rezago (DANE publica 45 días después del cierre del trimestre).
- Entre el cierre de un trimestre y la publicación oficial, los hacedores de política, analistas de mercado y el sector privado deben tomar decisiones sin saber aún qué pasó con la economía.
- En contraste, existe un conjunto amplio de indicadores de alta frecuencia (mensual) disponibles casi en tiempo real: ISE, producción manufacturera, ventas del comercio, inflación, tasa de cambio, tasa de política monetaria, precio del petróleo.

Introducción - Problema

El Problema

- El PIB es el indicador más importante para monitorear el ciclo económico, pero en Colombia (como en la mayoría de países) se publica trimestralmente y con rezago (DANE publica 45 días después del cierre del trimestre).
- Entre el cierre de un trimestre y la publicación oficial, los hacedores de política, analistas de mercado y el sector privado deben tomar decisiones sin saber aún qué pasó con la economía.
- En contraste, existe un conjunto amplio de indicadores de alta frecuencia (mensual) disponibles casi en tiempo real: ISE, producción manufacturera, ventas del comercio, inflación, tasa de cambio, tasa de política monetaria, precio del petróleo.

Introducción - Problema

El Problema

- El PIB es el indicador más importante para monitorear el ciclo económico, pero en Colombia (como en la mayoría de países) se publica trimestralmente y con rezago (DANE publica 45 días después del cierre del trimestre).
- Entre el cierre de un trimestre y la publicación oficial, los hacedores de política, analistas de mercado y el sector privado deben tomar decisiones sin saber aún qué pasó con la economía.
- En contraste, existe un conjunto amplio de indicadores de alta frecuencia (mensual) disponibles casi en tiempo real: ISE, producción manufacturera, ventas del comercio, inflación, tasa de cambio, tasa de política monetaria, precio del petróleo.

Introducción - Problema

- El ***nowcasting*** busca cerrar esa brecha: usar la información mensual disponible para estimar el crecimiento del trimestre antes de que se publique el dato oficial.
- Limitación central: desfase de frecuencia y de tiempo entre el PIB (trimestral, rezagado) y los indicadores de actividad (mensuales, casi en tiempo real).

Introducción - Problema

- El ***nowcasting*** busca cerrar esa brecha: usar la información mensual disponible para estimar el crecimiento del trimestre antes de que se publique el dato oficial.
- Limitación central: desfase de frecuencia y de tiempo entre el PIB (trimestral, rezagado) y los indicadores de actividad (mensuales, casi en tiempo real).
- Agregar mecánicamente los datos mensuales a trimestral para esperar y estimar un VAR trimestral desperdicia información —se pierde la actualización progresiva que ocurre mes a mes dentro de cada trimestre.

Introducción - Problema

- El ***nowcasting*** busca cerrar esa brecha: usar la información mensual disponible para estimar el crecimiento del trimestre antes de que se publique el dato oficial.
- Limitación central: desfase de frecuencia y de tiempo entre el PIB (trimestral, rezagado) y los indicadores de actividad (mensuales, casi en tiempo real).
- Agregar mecánicamente los datos mensuales a trimestral para «esperar» y estimar un VAR trimestral desperdicia información — se pierde la actualización progresiva que ocurre mes a mes dentro de cada trimestre.

Introducción - Problema

- El ***nowcasting*** busca cerrar esa brecha: usar la información mensual disponible para estimar el crecimiento del trimestre antes de que se publique el dato oficial.
- Limitación central: desfase de frecuencia y de tiempo entre el PIB (trimestral, rezagado) y los indicadores de actividad (mensuales, casi en tiempo real).
- Agregar mecánicamente los datos mensuales a trimestral para «esperar» y estimar un VAR trimestral desperdicia información — se pierde la actualización progresiva que ocurre mes a mes dentro de cada trimestre.

Introducción - Problema

- El ***nowcasting*** busca cerrar esa brecha: usar la información mensual disponible para estimar el crecimiento del trimestre antes de que se publique el dato oficial.
- Limitación central: desfase de frecuencia y de tiempo entre el PIB (trimestral, rezagado) y los indicadores de actividad (mensuales, casi en tiempo real).
- Agregar mecánicamente los datos mensuales a trimestral para «esperar» y estimar un VAR trimestral desperdicia información — se pierde la actualización progresiva que ocurre mes a mes dentro de cada trimestre.

Introducción - Problema

- Necesidad de un marco que:
  - Actualice el pronóstico cada vez que llega un nuevo dato mensual (no solo al cierre del trimestre)
  - Maneje el ragged edge (distintos calendarios de publicación: el ISE sale antes que la inflación, que sale antes que el PIB, etc.) sin forzar a todas las series al mismo calendario
  - Sea manejable en un país con series relativamente cortas y alta volatilidad macroeconómica (commodities, tasa de cambio)
- Esto motiva un MF-BVAR (Bayesian Mixed-Frequency VAR), que trata al PIB como una variable latente mensual parcialmente observada.

Introducción - Problema

- Necesidad de un marco que:
  - Actualice el pronóstico cada vez que llega un nuevo dato mensual (no solo al cierre del trimestre)
  - Maneje el ragged edge (distintos calendarios de publicación: el ISE sale antes que la inflación, que sale antes que el PIB, etc.) sin forzar a todas las series al mismo calendario
  - Sea manejable en un país con series relativamente cortas y alta volatilidad macroeconómica (commodities, tasa de cambio)
- Esto motiva un MF-BVAR (Bayesian Mixed-Frequency VAR), que trata al PIB como una variable latente mensual parcialmente observada.

Introducción - Problema

- Necesidad de un marco que:
  - Actualice el pronóstico cada vez que llega un nuevo dato mensual (no solo al cierre del trimestre)
  - Maneje el ragged edge (distintos calendarios de publicación: el ISE sale antes que la inflación, que sale antes que el PIB, etc.) sin forzar a todas las series al mismo calendario
  - Sea manejable en un país con series relativamente cortas y alta volatilidad macroeconómica (commodities, tasa de cambio)
- Esto motiva un MF-BVAR (Bayesian Mixed-Frequency VAR), que trata al PIB como una variable latente mensual parcialmente observada.

Introducción - Problema

- Necesidad de un marco que:
  - Actualice el pronóstico cada vez que llega un nuevo dato mensual (no solo al cierre del trimestre)
  - Maneje el ragged edge (distintos calendarios de publicación: el ISE sale antes que la inflación, que sale antes que el PIB, etc.) sin forzar a todas las series al mismo calendario
  - Sea manejable en un país con series relativamente cortas y alta volatilidad macroeconómica (commodities, tasa de cambio)
- Esto motiva un MF-BVAR (Bayesian Mixed-Frequency VAR), que trata al PIB como una variable latente mensual parcialmente observada.

Introducción - Problema

- Necesidad de un marco que:
  - Actualice el pronóstico cada vez que llega un nuevo dato mensual (no solo al cierre del trimestre)
  - Maneje el ragged edge (distintos calendarios de publicación: el ISE sale antes que la inflación, que sale antes que el PIB, etc.) sin forzar a todas las series al mismo calendario
  - Sea manejable en un país con series relativamente cortas y alta volatilidad macroeconómica (commodities, tasa de cambio)
- Esto motiva un MF-BVAR (Bayesian Mixed-Frequency VAR), que trata al PIB como una variable latente mensual parcialmente observada.

Introducción - Problema

¿Por qué un enfoque bayesiano?

- Un VAR mensual con varias variables y varios rezagos tiene muchos parámetros en relación con el número de observaciones disponibles (*sobreparametrización*) — estimarlo por MV/OLS sin restricciones produce coeficientes muy inestables y sobreajuste.
- El enfoque bayesiano permite introducir *priors* de contracción (*shrinkage*), el prior de Minnesota (Litterman, 1986).

Introducción - Problema

¿Por qué un enfoque bayesiano?

- Un VAR mensual con varias variables y varios rezagos tiene muchos parámetros en relación con el número de observaciones disponibles (*sobreparametrización*) — estimarlo por MV/OLS sin restricciones produce coeficientes muy inestables y sobreajuste.
- El enfoque bayesiano permite introducir *priors* de contracción (*shrinkage*), el prior de Minnesota (Litterman, 1986):

Introducción - Problema

¿Por qué un enfoque bayesiano?

- Un VAR mensual con varias variables y varios rezagos tiene muchos parámetros en relación con el número de observaciones disponibles (*sobreparametrización*) — estimarlo por MV/OLS sin restricciones produce coeficientes muy inestables y sobreajuste.
- El enfoque bayesiano permite introducir *priors* de contracción (*shrinkage*), el prior de Minnesota (Litterman, 1986):
  - Regulariza los coeficientes hacia una estructura parsimoniosa (ej. paseo aleatorio) sin eliminar variables arbitrariamente
  - Permite incluir más variables e indicadores de los que un VAR clásico toleraría con series relativamente cortas,
  - Mejora la precisión fuera de muestra frente a alternativas no restringidas (Bańbura, Giannone y Reichlin (2010)).

Introducción - Problema

¿Por qué un enfoque bayesiano?

- Un VAR mensual con varias variables y varios rezagos tiene muchos parámetros en relación con el número de observaciones disponibles (*sobreparametrización*) — estimarlo por MV/OLS sin restricciones produce coeficientes muy inestables y sobreajuste.
- El enfoque bayesiano permite introducir *priors* de contracción (*shrinkage*), el prior de Minnesota (Litterman, 1986):
  - Regulariza los coeficientes hacia una estructura parsimoniosa (ej. paseo aleatorio) sin eliminar variables arbitrariamente
  - Permite incluir más variables e indicadores de los que un VAR clásico toleraría con series relativamente cortas,
  - Mejora la precisión fuera de muestra frente a alternativas no restringidas (Bańbura, Giannone y Reichlin (2010)).

Introducción - Problema

¿Por qué un enfoque bayesiano?

- Un VAR mensual con varias variables y varios rezagos tiene muchos parámetros en relación con el número de observaciones disponibles (*sobreparametrización*) — estimarlo por MV/OLS sin restricciones produce coeficientes muy inestables y sobreajuste.
- El enfoque bayesiano permite introducir *priors* de contracción (*shrinkage*), el prior de Minnesota (Litterman, 1986):
  - Regulariza los coeficientes hacia una estructura parsimoniosa (ej. paseo aleatorio) sin eliminar variables arbitrariamente
  - Permite incluir más variables e indicadores de los que un VAR clásico toleraría con series relativamente cortas,
  - Mejora la precisión fuera de muestra frente a alternativas no restringidas (Bańbura, Giannone y Reichlin (2010)).

Introducción - Problema

¿Por qué un enfoque bayesiano?

- Un VAR mensual con varias variables y varios rezagos tiene muchos parámetros en relación con el número de observaciones disponibles (*sobreparametrización*) — estimarlo por MV/OLS sin restricciones produce coeficientes muy inestables y sobreajuste.
- El enfoque bayesiano permite introducir *priors* de contracción (*shrinkage*), el prior de Minnesota (Litterman, 1986):
  - Regulariza los coeficientes hacia una estructura parsimoniosa (ej. paseo aleatorio) sin eliminar variables arbitrariamente
  - Permite incluir más variables e indicadores de los que un VAR clásico toleraría con series relativamente cortas,
  - Mejora la precisión fuera de muestra frente a alternativas no restringidas (Bańbura, Giannone y Reichlin (2010)).

Introducción - Problema

¿Por qué un enfoque bayesiano?

- Además, el marco bayesiano entrega una distribución *posterior* completa del pronóstico (no solo un punto), lo que permite cuantificar la incertidumbre alrededor del **nowcast** — información valiosa para el análisis de riesgo y la comunicación de política.
- El tratamiento de frecuencia mixta (*variable trimestral parcialmente observada*) se resuelve de forma natural dentro de una representación de espacio de estados (**filtro de Kalman**), que es el marco estándar para inferencia bayesiana en modelos dinámicos.

Introducción - Problema

¿Por qué un enfoque bayesiano?

- Además, el marco bayesiano entrega una distribución *posterior* completa del pronóstico (no solo un punto), lo que permite cuantificar la incertidumbre alrededor del **nowcast** — información valiosa para el análisis de riesgo y la comunicación de política.
- El tratamiento de frecuencia mixta (*variable trimestral parcialmente observada*) se resuelve de forma natural dentro de una representación de espacio de estados (**filtro de Kalman**), que es el marco estándar para inferencia bayesiana en modelos dinámicos.

Introducción - Problema

¿Por qué un enfoque bayesiano?

- Además, el marco bayesiano entrega una distribución *posterior* completa del pronóstico (no solo un punto), lo que permite cuantificar la incertidumbre alrededor del **nowcast** — información valiosa para el análisis de riesgo y la comunicación de política.
- El tratamiento de frecuencia mixta (*variable trimestral parcialmente observada*) se resuelve de forma natural dentro de una representación de espacio de estados (**filtro de Kalman**), que es el marco estándar para inferencia bayesiana en modelos dinámicos.

Introducción - Problema

Objetivo general

Proponer y estimar un modelo de *nowcasting* del crecimiento económico de Colombia mediante un Bayesian Mixed-Frequency VAR (MF-BVAR), que permita actualizar el pronóstico del PIB trimestral a partir de indicadores mensuales de actividad real, precios, condiciones financieras y sector externo.

Marco Teórico y Revisión de Bibliografía

- Giannone, Reichlin y Small (2008): definen el nowcasting como la actualización continua del pronóstico del trimestre corriente conforme llega nueva información.
- Mariano y Murasawa (2003): proponen el índice coincidente basado en series mensuales y trimestrales — base de la identidad de agregación en un MF-BVAR.
- Kuzin, Marcellino y Schumacher (2011): comparan MIDAS vs. VAR de frecuencia mixta para nowcasting del PIB de la eurozona.
- Carriero, Clark y Marcellino (2015): extienden el MF-BVAR con volatilidad estocástica para pronóstico en tiempo real.

Marco Teórico y Revisión de Bibliografía

- Giannone, Reichlin y Small (2008): definen el nowcasting como la actualización continua del pronóstico del trimestre corriente conforme llega nueva información.
- Mariano y Murasawa (2003): proponen el índice coincidente basado en series mensuales y trimestrales — base de la identidad de agregación en un MF-BVAR.
- Kuzin, Marcellino y Schumacher (2011): comparan MIDAS vs. VAR de frecuencia mixta para nowcasting del PIB de la eurozona.
- Carriero, Clark y Marcellino (2015): extienden el MF-BVAR con volatilidad estocástica para pronóstico en tiempo real.

Marco Teórico y Revisión de Bibliografía

- Giannone, Reichlin y Small (2008): definen el nowcasting como la actualización continua del pronóstico del trimestre corriente conforme llega nueva información.
- Mariano y Murasawa (2003): proponen el índice coincidente basado en series mensuales y trimestrales — base de la identidad de agregación en un MF-BVAR.
- Kuzin, Marcellino y Schumacher (2011): comparan MIDAS vs. VAR de frecuencia mixta para nowcasting del PIB de la eurozona.
- Carriero, Clark y Marcellino (2015): extienden el MF-BVAR con volatilidad estocástica para pronóstico en tiempo real.

Marco Teórico y Revisión de Bibliografía

- Giannone, Reichlin y Small (2008): definen el nowcasting como la actualización continua del pronóstico del trimestre corriente conforme llega nueva información.
- Mariano y Murasawa (2003): proponen el índice coincidente basado en series mensuales y trimestrales — base de la identidad de agregación en un MF-BVAR.
- Kuzin, Marcellino y Schumacher (2011): comparan MIDAS vs. VAR de frecuencia mixta para nowcasting del PIB de la eurozona.
- Carriero, Clark y Marcellino (2015): extienden el MF-BVAR con volatilidad estocástica para pronóstico en tiempo real.

Marco Teórico y Revisión de Bibliografía

- Litterman (1986): origen del *prior* de Minnesota.
- Banbura, Giannone y Reichlin (2010): BVAR grandes con contracción — muestran que permite incluir muchas variables sin perder precisión predictiva.
- Schorfheide y Song (2015): desarrollan el marco de pronóstico en tiempo real que combina variables mensuales y trimestrales en una estructura VAR de frecuencia mixta.

Marco Teórico y Revisión de Bibliografía

- Litterman (1986): origen del *prior* de Minnesota.
- Banbura, Giannone y Reichlin (2010): BVAR grandes con contracción — muestran que permite incluir muchas variables sin perder precisión predictiva.
- Schorfheide y Song (2015): desarrollan el marco de pronóstico en tiempo real que combina variables mensuales y trimestrales en una estructura VAR de frecuencia mixta.

Marco Teórico y Revisión de Bibliografía

- Litterman (1986): origen del *prior* de Minnesota.
- Banbura, Giannone y Reichlin (2010): BVAR grandes con contracción — muestran que permite incluir muchas variables sin perder precisión predictiva.
- Schorfheide y Song (2015): desarrollan el marco de pronóstico en tiempo real que combina variables mensuales y trimestrales en una estructura VAR de frecuencia mixta.

Datos

Se construye un sistema de frecuencia mixta con **9 variables** para Colombia, combinando una serie trimestral objetivo y ocho indicadores mensuales de actividad real, precios, condiciones monetarias y sector externo.

Variable	Frecuencia	Fuente	Rol
PIB real	Trimestral	DANE	Variable objetivo
ISE	Mensual	DANE	Actividad económica agregada
IPI (Producción industrial)	Mensual	DANE	Sector manufacturero
Tasa de desempleo	Mensual	DANE	Mercado laboral
Inflación (IPC)	Mensual	DANE	Precios
TRM	Mensual	Banco de la República	Sector externo / financiero
Tasa de política monetaria	Mensual	Banco de la República	Condiciones monetarias
Petróleo (Brent)	Mensual	Mercados internacionales	Choque externo (términos de intercambio)
IEC	Mensual	Fedesarrollo	Expectativas

Datos

Se construye un sistema de frecuencia mixta con **9 variables** para Colombia, combinando una serie trimestral objetivo y ocho indicadores mensuales de actividad real, precios, condiciones monetarias y sector externo.

Variable	**Frecuencia**	**Fuente**	**Rol**
PIB real	Trimestral	DANE	Variable objetivo
ISE	Mensual	DANE	Actividad económica agregada
IPI (Producción industrial)	Mensual	DANE	Sector manufacturero
Tasa de desempleo	Mensual	DANE	Mercado laboral
Inflación (IPC)	Mensual	DANE	Precios
TRM	Mensual	Banco de la República	Sector externo / financiero
Tasa de política monetaria	Mensual	Banco de la República	Condiciones monetarias
Petróleo (Brent)	Mensual	Mercados internacionales	Choque externo (términos de intercambio)
IEC	Mensual	Fedesarrollo	Expectativas

Datos

Muestra y Transformaciones

- **Muestra histórica**: 2014–2025 (144 meses, 48 trimestres).
- **Muestra de nowcasting**: 2021–2025 (submuestra reciente, usada para el ejercicio de pronóstico en tiempo real).
- Todas las series mensuales se emplean desestacionalizadas.
- Las variables se modelan **en niveles**; la no estacionariedad se controla directamente a través del *prior* de Minnesota, que impone la hipótesis de *random walk* sobre el primer rezago propio de cada variable.

Datos

Muestra y Transformaciones

- **Muestra histórica**: 2014–2025 (144 meses, 48 trimestres).
- **Muestra de nowcasting**: 2021–2025 (submuestra reciente, usada para el ejercicio de pronóstico en tiempo real).
- Todas las series mensuales se emplean desestacionalizadas.
- Las variables se modelan **en niveles**; la no estacionariedad se controla directamente a través del *prior* de Minnesota, que impone la hipótesis de *random walk* sobre el primer rezago propio de cada variable.

Datos

Muestra y Transformaciones

- **Muestra histórica**: 2014–2025 (144 meses, 48 trimestres).
- **Muestra de nowcasting**: 2021–2025 (submuestra reciente, usada para el ejercicio de pronóstico en tiempo real).
- Todas las series mensuales se emplean desestacionalizadas.
- Las variables se modelan **en niveles**; la no estacionariedad se controla directamente a través del *prior* de Minnesota, que impone la hipótesis de *random walk* sobre el primer rezago propio de cada variable.

Datos

Muestra y Transformaciones

- **Muestra histórica**: 2014–2025 (144 meses, 48 trimestres).
- **Muestra de nowcasting**: 2021–2025 (submuestra reciente, usada para el ejercicio de pronóstico en tiempo real).
- Todas las series mensuales se emplean desestacionalizadas.
- Las variables se modelan **en niveles**; la no estacionariedad se controla directamente a través del *prior* de Minnesota, que impone la hipótesis de *random walk* sobre el primer rezago propio de cada variable.

Metodología

Panorama General

El modelo se estima en tres etapas:

1. **Especificación**: VAR mensual en forma de espacio de estados, con el PIB trimestral como variable parcialmente observada (Schorfheide y Song, 2015).
2. **Estimación bayesiana**: muestreador de Gibbs, combinando simulación de estados (Carter-Kohn, 1994) y actualización de parámetros bajo *prior* de Minnesota.
3. **Pronóstico**: [illegible]

Metodología

Panorama General

El modelo se estima en tres etapas:

1. **Especificación**: VAR mensual en forma de espacio de estados, con el PIB trimestral como variable parcialmente observada (Schorfheide y Song, 2015).
2. **Estimación bayesiana**: muestreador de Gibbs, combinando simulación de estados (Carter-Kohn, 1994) y actualización de parámetros bajo *prior* de Minnesota.

Metodología

Panorama General

El modelo se estima en tres etapas:

1. **Especificación**: VAR mensual en forma de espacio de estados, con el PIB trimestral como variable parcialmente observada (Schorfheide y Song, 2015).
2. **Estimación bayesiana**: muestreador de Gibbs, combinando simulación de estados (Carter-Kohn, 1994) y actualización de parámetros bajo *prior* de Minnesota.
3. **Proyección**: densidad predictiva conjunta del PIB mensual latente, agregada de forma consistente al horizonte trimestral de interés.

Metodología

Panorama General

El modelo se estima en tres etapas:

1. **Especificación**: VAR mensual en forma de espacio de estados, con el PIB trimestral como variable parcialmente observada (Schorfheide y Song, 2015).
2. **Estimación bayesiana**: muestreador de Gibbs, combinando simulación de estados (Carter-Kohn, 1994) y actualización de parámetros bajo *prior* de Minnesota.
3. **Proyección**: densidad predictiva conjunta del PIB mensual latente, agregada de forma consistente al horizonte trimestral de interés.

Metodología

Panorama General

El modelo se estima en tres etapas:

1. **Especificación**: VAR mensual en forma de espacio de estados, con el PIB trimestral como variable parcialmente observada (Schorfheide y Song, 2015).
2. **Estimación bayesiana**: muestreador de Gibbs, combinando simulación de estados (Carter-Kohn, 1994) y actualización de parámetros bajo *prior* de Minnesota.
3. **Proyección**: densidad predictiva conjunta del PIB mensual latente, agregada de forma consistente al horizonte trimestral de interés.

Metodología

Panorama General

El modelo se estima en tres etapas:

1. **Especificación**: VAR mensual en forma de espacio de estados, con el PIB trimestral como variable parcialmente observada (Schorfheide y Song, 2015).
2. **Estimación bayesiana**: muestreador de Gibbs, combinando simulación de estados (Carter-Kohn, 1994) y actualización de parámetros bajo *prior* de Minnesota.
3. **Proyección**: densidad predictiva conjunta del PIB mensual latente, agregada de forma consistente al horizonte trimestral de interés.

Metodología

Formulación del Modelo de Espacio de Estados MF-VAR

Sea $x_t = [x'_{m,t}, x'_{q,t}]'$ un vector $n \times 1$ de variables macroeconómicas. La ecuación de transición mensual en representación compañera $np \times 1$ es:

$$Z_t = F(\Phi)Z_{t-1} + F_c(\Phi) + V_t, \quad V_t \sim \text{i.i.d. } N(0, \Omega(\Sigma))$$

Donde la matriz compañera $F(\Phi)$ y la covarianza singular $\Omega(\Sigma)$ se definen como:

$$F(\Phi) = \begin{bmatrix} \Phi_1 & \Phi_2 & \cdots & \Phi_p \\ I_{n(p-1)} & & 0_{n(p-1)\times n} & \end{bmatrix}, \quad \Omega(\Sigma) = \begin{bmatrix} \Sigma & 0 \\ 0 & 0 \end{bmatrix}$$

Metodología

Formulación del Modelo de Espacio de Estados MF-VAR

Sea $x_t = [x'_{m,t}, x'_{q,t}]'$ un vector $n \times 1$ de variables macroeconómicas. La ecuación de transición mensual en representación compañera $np \times 1$ es:

$$Z_t = F(\Phi)Z_{t-1} + F_c(\Phi) + V_t, \quad V_t \sim \text{i.i.d. } N(0, \Omega(\Sigma))$$

Donde la matriz compañera $F(\Phi)$ y la covarianza singular $\Omega(\Sigma)$ se definen como:

$$F(\Phi) = \begin{bmatrix} \Phi_1 & \Phi_2 & \cdots & \Phi_p \\ I_{n(p-1)} & & 0_{n(p-1)\times n} & \end{bmatrix}, \quad \Omega(\Sigma) = \begin{bmatrix} \Sigma & 0 \\ 0 & 0 \end{bmatrix}$$

Metodología

Formulación del Modelo de Espacio de Estados MF-VAR

Sea $x_t = [x'_{m,t}, x'_{q,t}]'$ un vector $n \times 1$ de variables macroeconómicas. La ecuación de transición mensual en representación compañera $np \times 1$ es:

$$Z_t = F(\Phi)Z_{t-1} + F_c(\Phi) + V_t, \quad V_t \sim \text{i.i.d. } N(0, \Omega(\Sigma))$$

Donde la matriz compañera $F(\Phi)$ y la covarianza singular $\Omega(\Sigma)$ se definen como:

$$F(\Phi) = \begin{bmatrix} \Phi_1 & \Phi_2 & \cdots & \Phi_p \\ I_{n(p-1)} & & 0_{n(p-1)\times n} & \end{bmatrix}, \quad \Omega(\Sigma) = \begin{bmatrix} \Sigma & 0 \\ 0 & 0 \end{bmatrix}$$

Metodología

Formulación del Modelo de Espacio de Estados MF-VAR

Sea $x_t = [x'_{m,t}, x'_{q,t}]'$ un vector $n \times 1$ de variables macroeconómicas. La ecuación de transición mensual en representación compañera $np \times 1$ es:

$$Z_t = F(\Phi)Z_{t-1} + F_c(\Phi) + V_t, \quad V_t \sim \text{i.i.d. } N(0, \Omega(\Sigma))$$

Donde la matriz compañera $F(\Phi)$ y la covarianza singular $\Omega(\Sigma)$ se definen como:

$$F(\Phi) = \begin{bmatrix} \Phi_1 & \Phi_2 & \cdots & \Phi_p \\ I_{n(p-1)} & & 0_{n(p-1)\times n} & \end{bmatrix}, \quad \Omega(\Sigma) = \begin{bmatrix} \Sigma & 0 \\ 0 & 0 \end{bmatrix}$$

Metodología

Formulación del Modelo de Espacio de Estados MF-VAR

La ecuación de medición en presencia de datos faltantes temporales

$$Y_t^{obs} = M_t \Lambda Z_t$$

donde Λ es la matriz de agregación temporal *log-lineal* y M_t es la matriz de selección variante que depura las celdas vacías (NA) en cada mes t, solucionando estructuralmente el problema del ***ragged edge*** (borde irregular) en la publicación de datos.
En el horizonte $T+1, \ldots, T+H$, el PIB mensual latente $x^*_{q,T+h}$ se proyecta mediante la densidad predictiva conjunta:

$$p(Z_{T+1:T+H} \mid Y_{1:T}^{obs}) = \int p(Z_{T+1:T+H} \mid Z_T, \Phi, \Sigma) p(\Phi, \Sigma \mid Y_{1:T}^{obs}, Z_{1:T})\, d(\Phi, \Sigma)$$

Metodología

Formulación del Modelo de Espacio de Estados MF-VAR

La ecuación de medición en presencia de datos faltantes temporales

$$Y_t^{obs} = M_t \Lambda Z_t$$

donde Λ es la matriz de agregación temporal *log-lineal* y M_t es la matriz de selección variante que depura las celdas vacías (NA) en cada mes t, solucionando estructuralmente el problema del ***ragged edge*** (borde irregular) en la publicación de datos.
En el horizonte $T+1, \ldots, T+H$, el PIB mensual latente $x^*_{q,T+h}$ se proyecta mediante la densidad predictiva conjunta:

$$p(Z_{T+1:T+H} \mid Y^{obs}_{1:T}) = \int p(Z_{T+1:T+H} \mid Z_T, \Phi, \Sigma) p(\Phi, \Sigma \mid Y^{obs}_{1:T}, Z_{1:T})\, d(\Phi, \Sigma)$$

Metodología

Formulación del Modelo de Espacio de Estados MF-VAR

La ecuación de medición en presencia de datos faltantes temporales

$$Y_t^{obs} = M_t \Lambda Z_t$$

donde Λ es la matriz de agregación temporal *log-lineal* y M_t es la matriz de selección variante que depura las celdas vacías (NA) en cada mes t, solucionando estructuralmente el problema del ***ragged edge*** (borde irregular) en la publicación de datos.

En el horizonte $T+1, \ldots, T+H$, el PIB mensual latente $x^*_{q,T+h}$ se proyecta mediante la densidad predictiva conjunta:

$$p(Z_{T+1:T+H} \mid Y_{1:T}^{obs}) = \int p(Z_{T+1:T+H} \mid Z_T, \Phi, \Sigma) p(\Phi, \Sigma \mid Y_{1:T}^{obs}, Z_{1:T})\, d(\Phi, \Sigma)$$

Metodología

Formulación del Modelo de Espacio de Estados MF-VAR

La ecuación de medición en presencia de datos faltantes temporales

$$Y_t^{obs} = M_t \Lambda Z_t$$

donde Λ es la matriz de agregación temporal *log-lineal* y M_t es la matriz de selección variante que depura las celdas vacías (NA) en cada mes t, solucionando estructuralmente el problema del ***ragged edge*** (borde irregular) en la publicación de datos.
En el horizonte $T+1, \ldots, T+H$, el PIB mensual latente $x^*_{q,T+h}$ se proyecta mediante la densidad predictiva conjunta:

$$p(Z_{T+1:T+H} \mid Y_{1:T}^{obs}) = \int p(Z_{T+1:T+H} \mid Z_T, \Phi, \Sigma) p(\Phi, \Sigma \mid Y_{1:T}^{obs}, Z_{1:T})\, d(\Phi, \Sigma)$$

Metodología

Formulación del Modelo de Espacio de Estados MF-VAR

La ecuación de medición en presencia de datos faltantes temporales

$$Y_t^{obs} = M_t \Lambda Z_t$$

donde Λ es la matriz de agregación temporal *log-lineal* y M_t es la matriz de selección variante que depura las celdas vacías (NA) en cada mes t, solucionando estructuralmente el problema del ***ragged edge*** (borde irregular) en la publicación de datos.
En el horizonte $T+1, \ldots, T+H$, el PIB mensual latente $x^*_{q,T+h}$ se proyecta mediante la densidad predictiva conjunta:

$$p(Z_{T+1:T+H} \mid Y_{1:T}^{obs}) = \int p(Z_{T+1:T+H} \mid Z_T, \Phi, \Sigma) p(\Phi, \Sigma \mid Y_{1:T}^{obs}, Z_{1:T})\, d(\Phi, \Sigma)$$

Metodología

Distribución Predictiva Posterior del Estado Latente

El muestreador de Gibbs simula esta distribución iterando sobre:

1. **Simulación de Estados (Carter-Kohn, 1994)**: Sorteo de la trayectoria $Z_{1:T}$ condicionado a los parámetros del modelo:

$$p(Z_{1:T} \mid Y_{1:T}^{obs}, \Phi, \Sigma) \propto p(Z_0) \prod_{t=1}^{T} p(Y_t^{obs} \mid Z_t) p(Z_t \mid Z_{t-1}, \Phi, \Sigma)$$

2. **Paso de Parámetros**: Sorteo de (Φ, Σ) condicionado al vector de estados simulado desde la posterior normal-Wishart inversa.

Metodología

Distribución Predictiva Posterior del Estado Latente

El muestreador de Gibbs simula esta distribución iterando sobre:

1. **Simulación de Estados (Carter-Kohn, 1994)**: Sorteo de la trayectoria $Z_{1:T}$ condicionado a los parámetros del modelo:

$$p(Z_{1:T} \mid Y_{1:T}^{obs}, \Phi, \Sigma) \propto p(Z_0) \prod_{t=1}^{T} p(Y_t^{obs} \mid Z_t) p(Z_t \mid Z_{t-1}, \Phi, \Sigma)$$

2. **Paso de Parámetros**: Sorteo de (Φ, Σ) condicionado al vector de estados simulado desde la posterior normal-Wishart inversa.

Metodología

Distribución Predictiva Posterior del Estado Latente

El muestreador de Gibbs simula esta distribución iterando sobre:

1. **Simulación de Estados (Carter-Kohn, 1994)**: Sorteo de la trayectoria $Z_{1:T}$ condicionado a los parámetros del modelo:

$$p(Z_{1:T} \mid Y_{1:T}^{obs}, \Phi, \Sigma) \propto p(Z_0) \prod_{t=1}^{T} p(Y_t^{obs} \mid Z_t) p(Z_t \mid Z_{t-1}, \Phi, \Sigma)$$

2. **Paso de Parámetros**: Sorteo de (Φ, Σ) condicionado al vector de estados simulado desde la posterior normal-Wishart inversa:

$$p(\Phi, \Sigma \mid Y_{1:T}^{obs}, Z_{1:T}) \propto MNIW(\Phi, \Psi, \Sigma, \nu)$$

Metodología

Distribución Predictiva Posterior del Estado Latente

El muestreador de Gibbs simula esta distribución iterando sobre:

1. **Simulación de Estados (Carter-Kohn, 1994)**: Sorteo de la trayectoria $Z_{1:T}$ condicionado a los parámetros del modelo:

$$p(Z_{1:T} \mid Y_{1:T}^{obs}, \Phi, \Sigma) \propto p(Z_0) \prod_{t=1}^{T} p(Y_t^{obs} \mid Z_t) p(Z_t \mid Z_{t-1}, \Phi, \Sigma)$$

2. **Paso de Parámetros**: Sorteo de (Φ, Σ) condicionado al vector de estados simulado desde la posterior normal-Wishart inversa:

$$p(\Phi, \Sigma \mid Y_{1:T}^{obs}, Z_{1:T}) \sim MNIW(\bar{\Phi}, \bar{\Psi}, \bar{\Sigma}, \bar{\nu})$$

Metodología

Distribución Predictiva Posterior del Estado Latente

El muestreador de Gibbs simula esta distribución iterando sobre:

1. **Simulación de Estados (Carter-Kohn, 1994)**: Sorteo de la trayectoria $Z_{1:T}$ condicionado a los parámetros del modelo:

$$p(Z_{1:T} \mid Y_{1:T}^{obs}, \Phi, \Sigma) \propto p(Z_0) \prod_{t=1}^{T} p(Y_t^{obs} \mid Z_t) p(Z_t \mid Z_{t-1}, \Phi, \Sigma)$$

2. **Paso de Parámetros**: Sorteo de (Φ, Σ) condicionado al vector de estados simulado desde la posterior normal-Wishart inversa:

$$p(\Phi, \Sigma \mid Y_{1:T}^{obs}, Z_{1:T}) \sim MNIW(\bar{\Phi}, \bar{\Psi}, \bar{\Sigma}, \bar{\nu})$$

Metodología

Distribución Predictiva Posterior del Estado Latente

El muestreador de Gibbs simula esta distribución iterando sobre:

1. **Simulación de Estados (Carter-Kohn, 1994)**: Sorteo de la trayectoria $Z_{1:T}$ condicionado a los parámetros del modelo:

$$p(Z_{1:T} \mid Y_{1:T}^{obs}, \Phi, \Sigma) \propto p(Z_0) \prod_{t=1}^{T} p(Y_t^{obs} \mid Z_t) p(Z_t \mid Z_{t-1}, \Phi, \Sigma)$$

2. **Paso de Parámetros**: Sorteo de (Φ, Σ) condicionado al vector de estados simulado desde la posterior normal-Wishart inversa:

$$p(\Phi, \Sigma \mid Y_{1:T}^{obs}, Z_{1:T}) \sim MNIW(\bar{\Phi}, \bar{\Psi}, \bar{\Sigma}, \bar{\nu})$$

Metodología

Proyección Dinámica y Agregación Consistente

El PIB mensual latente $PIB^*_{M,t}$ es una variable de estado estimada por la estructura dinámica del sistema, no un promedio de la serie trimestral.

- Como el PIB es una variable de flujo en niveles, la agregación trimestral opera estrictamente como una **restricción de medición** aditiva en el Filtro de Kalman:

$$PIB_{Q,t} = PIB^*_{M,t} + PIB^*_{M,t-1} + PIB^*_{M,t-2}$$

- Así, el pronóstico para Q1-2026 se calcula agregando los meses latentes proyectados de Enero, Febrero y Marzo de 2026.

Metodología

Proyección Dinámica y Agregación Consistente

El PIB mensual latente $PIB^*_{M,t}$ es una variable de estado estimada por la estructura dinámica del sistema, no un promedio de la serie trimestral.

- Como el PIB es una variable de flujo en niveles, la agregación trimestral opera estrictamente como una **restricción de medición** aditiva en el Filtro de Kalman:

$$PIB_{Q,t} = PIB^*_{M,t} + PIB^*_{M,t-1} + PIB^*_{M,t-2}$$

- Así, el pronóstico para Q1-2026 se calcula agregando los meses latentes proyectados de Enero, Febrero y Marzo de 2026:

Metodología

Proyección Dinámica y Agregación Consistente

El PIB mensual latente $PIB^*_{M,t}$ es una variable de estado estimada por la estructura dinámica del sistema, no un promedio de la serie trimestral.

- Como el PIB es una variable de flujo en niveles, la agregación trimestral opera estrictamente como una **restricción de medición** aditiva en el Filtro de Kalman:

$$PIB_{Q,t} = PIB^*_{M,t} + PIB^*_{M,t-1} + PIB^*_{M,t-2}$$

- Así, el pronóstico para Q1-2026 se calcula agregando los meses latentes proyectados de Enero, Febrero y Marzo de 2026:

Metodología

Proyección Dinámica y Agregación Consistente

El PIB mensual latente $PIB^*_{M,t}$ es una variable de estado estimada por la estructura dinámica del sistema, no un promedio de la serie trimestral.

- Como el PIB es una variable de flujo en niveles, la agregación trimestral opera estrictamente como una **restricción de medición** aditiva en el Filtro de Kalman:

$$PIB_{Q,t} = PIB^*_{M,t} + PIB^*_{M,t-1} + PIB^*_{M,t-2}$$

- Así, el pronóstico para Q1-2026 se calcula agregando los meses latentes proyectados de Enero, Febrero y Marzo de 2026:

Metodología

Calibración y Diagnósticos de Convergencia MCMC

- **Prior de Minnesota**: $\lambda_1 = 0{,}09$. Controla la contracción de los coeficientes hacia la hipótesis de *random walk* en cada variable.
- **Simulaciones**: 20,000 (*draws*), 10,000 calentamiento (*burn-in*).
- **Especificación de rezagos**: $p = 6$ en la muestra histórica completa; $p = 4$ en la submuestra de nowcasting (2021–2025), para evitar singularidad en la matriz de covarianza del prior.
- **Tamaño de muestra efectivo (ESS)**:
  - Un ESS alto (*relativo*) indica baja autocorrelación en la cadena y buena mezcla del muestreador de Gibbs (convergencia adecuada).

Metodología

Calibración y Diagnósticos de Convergencia MCMC

- **Prior de Minnesota**: $\lambda_1 = 0{,}09$. Controla la contracción de los coeficientes hacia la hipótesis de *random walk* en cada variable.
- **Simulaciones**: 20,000 (*draws*), 10,000 calentamiento (*burn-in*).
- **Especificación de rezagos**: $p = 6$ en la muestra histórica completa; $p = 4$ en la submuestra de nowcasting (2021–2025), para evitar singularidad en la matriz de covarianza del prior.
- **Tamaño de muestra efectivo (ESS)**:
  - Un ESS alto (*relativo*) indica baja autocorrelación en la cadena y buena mezcla del muestreador de Gibbs (convergencia adecuada).

Metodología

Calibración y Diagnósticos de Convergencia MCMC

- **Prior de Minnesota**: $\lambda_1 = 0{,}09$. Controla la contracción de los coeficientes hacia la hipótesis de *random walk* en cada variable.
- **Simulaciones**: 20,000 (*draws*), 10,000 calentamiento (*burn-in*).
- **Especificación de rezagos**: $p = 6$ en la muestra histórica completa; $p = 4$ en la submuestra de nowcasting (2021–2025), para evitar singularidad en la matriz de covarianza del prior.
- **Tamaño de muestra efectivo (ESS)**:
  - Muestra histórica ($p = 6$): ESS = 13,775.04
  - Muestra de nowcasting ($p = 4$): ESS = 9,257.47
- Un ESS alto (*relativo*) indica baja autocorrelación en la cadena y buena mezcla del muestreador de Gibbs (convergencia adecuada).

Metodología

Calibración y Diagnósticos de Convergencia MCMC

- **Prior de Minnesota**: $\lambda_1 = 0{,}09$. Controla la contracción de los coeficientes hacia la hipótesis de *random walk* en cada variable.
- **Simulaciones**: 20,000 (*draws*), 10,000 calentamiento (*burn-in*).
- **Especificación de rezagos**: $p = 6$ en la muestra histórica completa; $p = 4$ en la submuestra de nowcasting (2021–2025), para evitar singularidad en la matriz de covarianza del prior.
- **Tamaño de muestra efectivo (ESS)**:
  - Muestra histórica ($p = 6$): ESS = 13,775,04
  - Muestra de nowcasting ($p = 4$): ESS = 9,797,47
- Un ESS alto (*relativo*) indica baja autocorrelación en la cadena y buena mezcla del muestreador de Gibbs (convergencia adecuada).

Metodología

Calibración y Diagnósticos de Convergencia MCMC

- **Prior de Minnesota**: $\lambda_1 = 0{,}09$. Controla la contracción de los coeficientes hacia la hipótesis de *random walk* en cada variable.
- **Simulaciones**: 20,000 (*draws*), 10,000 calentamiento (*burn-in*).
- **Especificación de rezagos**: $p = 6$ en la muestra histórica completa; $p = 4$ en la submuestra de nowcasting (2021–2025), para evitar singularidad en la matriz de covarianza del prior.
- **Tamaño de muestra efectivo (ESS)**:
  - Muestra histórica ($p = 6$): ESS = 13,775,04
  - Muestra de nowcasting ($p = 4$): ESS = 9,797,47
- Un ESS alto (*relativo*) indica baja autocorrelación en la cadena y buena mezcla del muestreador de Gibbs (convergencia adecuada).

Metodología

Calibración y Diagnósticos de Convergencia MCMC

- **Prior de Minnesota**: $\lambda_1 = 0{,}09$. Controla la contracción de los coeficientes hacia la hipótesis de *random walk* en cada variable.
- **Simulaciones**: 20,000 (*draws*), 10,000 calentamiento (*burn-in*).
- **Especificación de rezagos**: $p = 6$ en la muestra histórica completa; $p = 4$ en la submuestra de nowcasting (2021–2025), para evitar singularidad en la matriz de covarianza del prior.
- **Tamaño de muestra efectivo (ESS)**:
  - Muestra histórica ($p = 6$): ESS = 13,775,04
  - Muestra de nowcasting ($p = 4$): ESS = 9,797,47
- Un ESS alto (*relativo*) indica baja autocorrelación en la cadena y buena mezcla del muestreador de Gibbs (convergencia adecuada).

Metodología

Calibración y Diagnósticos de Convergencia MCMC

- **Prior de Minnesota**: $\lambda_1 = 0{,}09$. Controla la contracción de los coeficientes hacia la hipótesis de *random walk* en cada variable.
- **Simulaciones**: 20,000 (*draws*), 10,000 calentamiento (*burn-in*).
- **Especificación de rezagos**: $p = 6$ en la muestra histórica completa; $p = 4$ en la submuestra de nowcasting (2021–2025), para evitar singularidad en la matriz de covarianza del prior.
- **Tamaño de muestra efectivo (ESS)**:
  - Muestra histórica ($p = 6$): ESS = 13,775,04
  - Muestra de nowcasting ($p = 4$): ESS = 9,797,47
- Un ESS alto (*relativo*) indica baja autocorrelación en la cadena y buena mezcla del muestreador de Gibbs (convergencia adecuada).

Estimaciones y Resultados

Evaluación Puntual del Nowcast

Comparación entre el dato observado de DANE y la mediana posterior del MF-BVAR para el trimestre evaluado:

Métrica / Fecha	Dato Real DANE	Mediana BVAR	Bandas 95 %	Error %
PIB real (niveles)	258,780.7	**257,736.6**	[252,880.7 a 262,695.5]	0.40 %
Crec. Inter (Q)	+0.58 %	**0.18 %**	[-1.70 % a 2.11 %]	—
Crec. Inter (Y)	+2.17 %	**1.76 %**	[-0.16 % a 3.72 %]	—

El error absoluto en niveles es de solo **0.40 %**, y el dato observado cae dentro del intervalo de credibilidad al 95 % en ambas métricas de crecimiento.

Estimaciones y Resultados

Evaluación Puntual del Nowcast

Comparación entre el dato observado de DANE y la mediana posterior del MF-BVAR para el trimestre evaluado:

Métrica / Fecha	Dato Real DANE	Mediana BVAR	Bandas 95 %	Error %
PIB real (niveles)	258,780.7	**257,736.6**	[252,880.7 a 262,695.5]	0.40 %
Crec. Inter (Q)	+0.58 %	**0.18 %**	[-1.70 % a 2.11 %]	—
Crec. Inter (Y)	+2.17 %	**1.76 %**	[-0.16 % a 3.72 %]	—

El error absoluto en niveles es de solo **0.40 %**, y el dato observado cae dentro del intervalo de credibilidad al 95 % en ambas métricas de crecimiento.

Estimaciones y Resultados

Evaluación Puntual del Nowcast

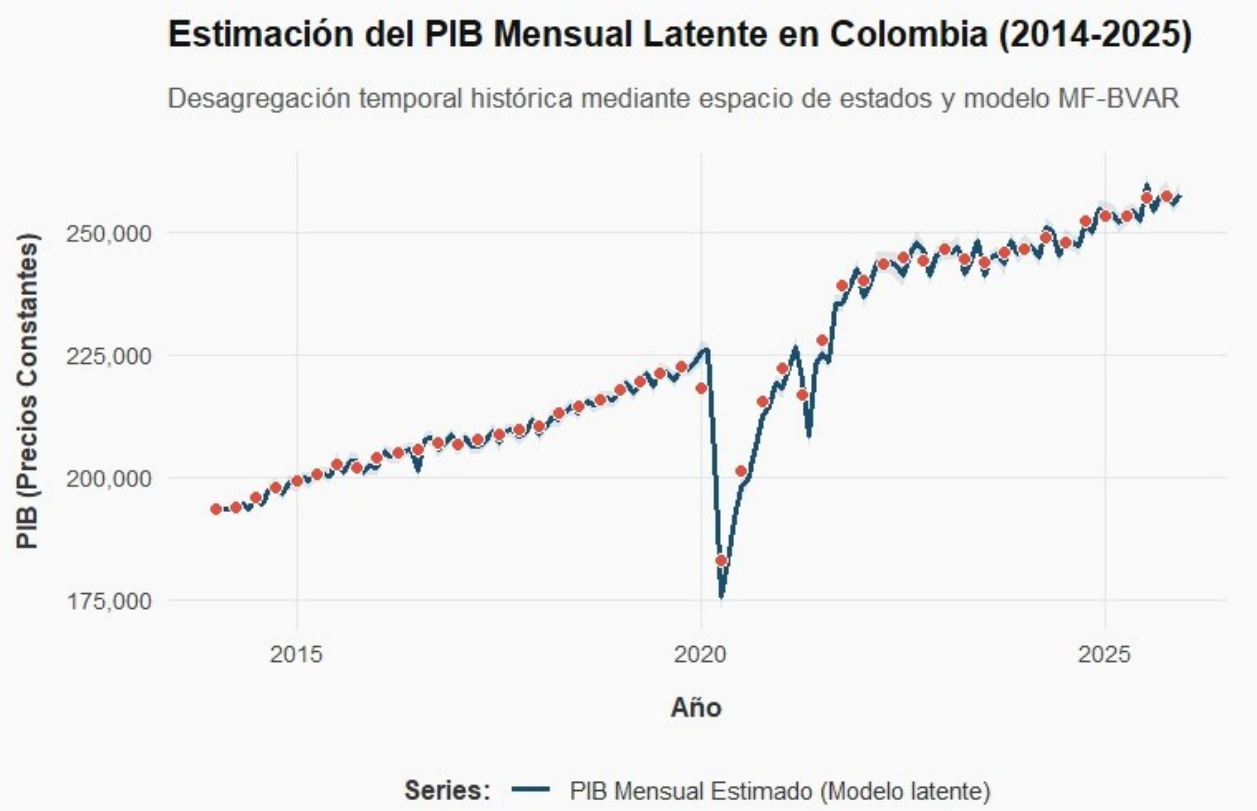
Comparación entre el dato observado de DANE y la mediana posterior del MF-BVAR para el trimestre evaluado:

Métrica / Fecha	Dato Real DANE	Mediana BVAR	Bandas 95 %	Error %
PIB real (niveles)	258,780.7	**257,736.6**	[252,880.7 a 262,695.5]	0.40 %
Crec. Inter (Q)	+0.58 %	**0.18 %**	[-1.70 % a 2.11 %]	—
Crec. Inter (Y)	+2.17 %	**1.76 %**	[-0.16 % a 3.72 %]	—

El error absoluto en niveles es de solo **0.40 %**, y el dato observado cae dentro del intervalo de credibilidad al 95 % en ambas métricas de crecimiento.

Estimaciones y Resultados

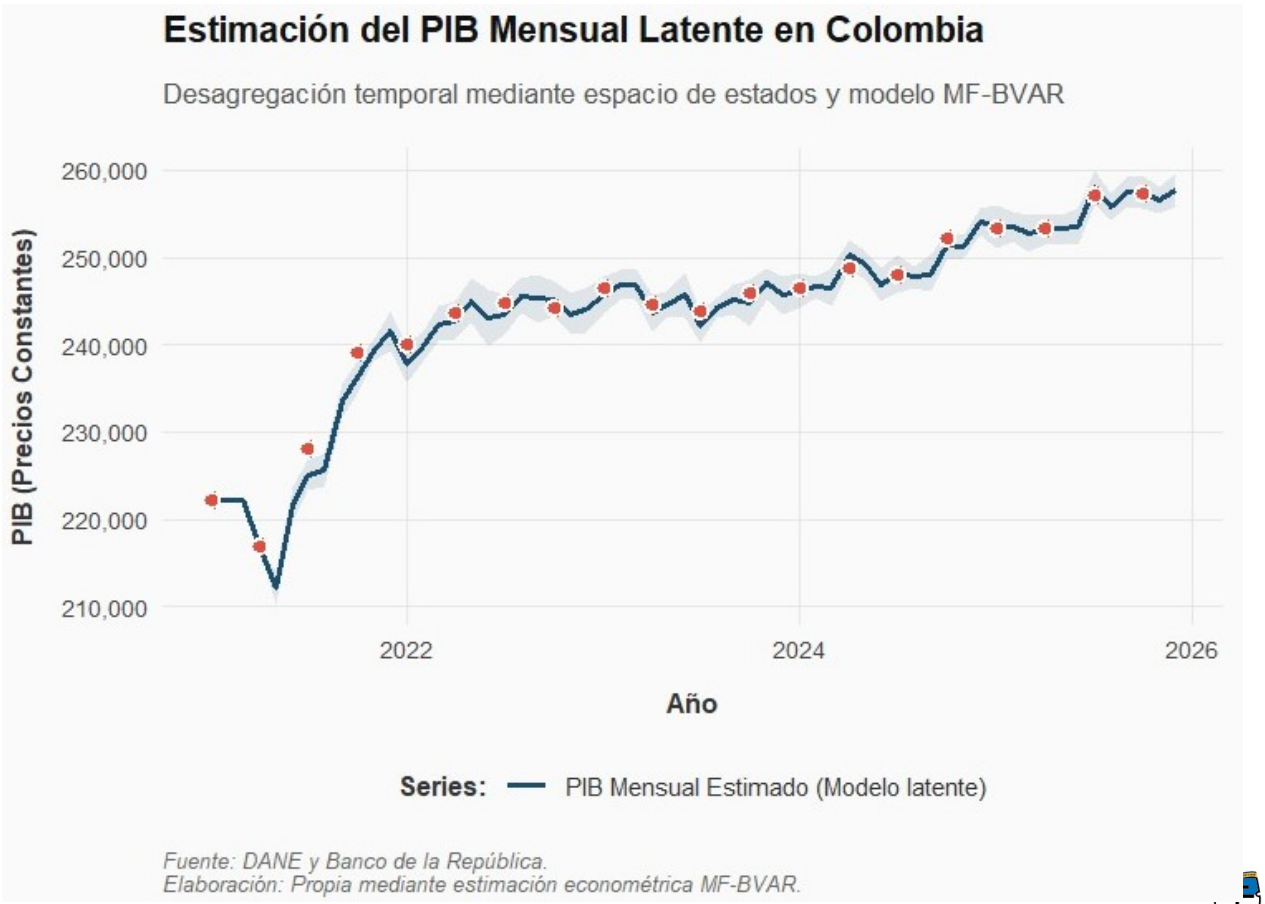
Trayectoria del Nowcast: Observado vs. Estimado



Fuente: DANE y Banco de la República.
Elaboración: Propia mediante estimación econométrica MF-BVAR.

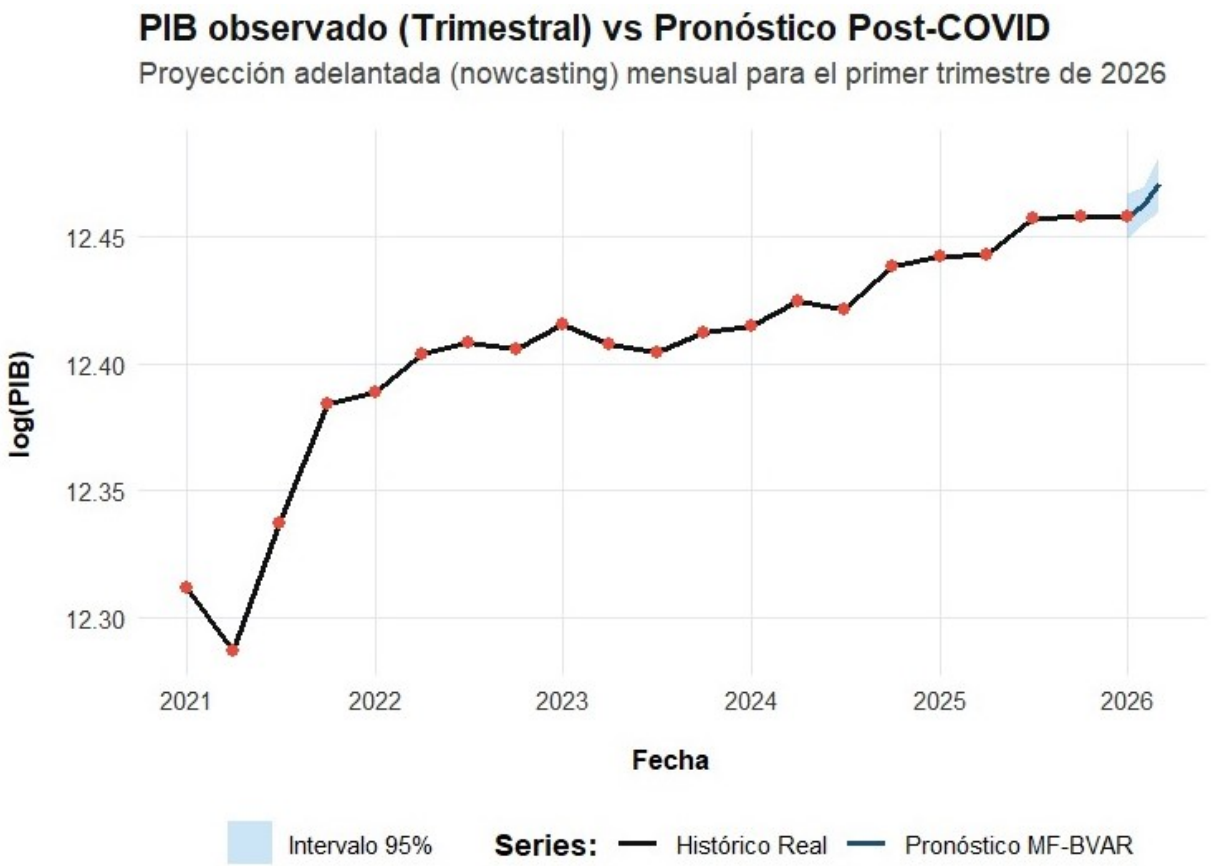
Estimaciones y Resultados

Trayectoria del Nowcast: Observado vs. Estimado



Estimaciones y Resultados

Pronóstico 2026-Q1



Consideraciones finales

- El MF-BVAR permite generar **nowcasts mensuales del PIB colombiano** explotando la información disponible antes de la publicación oficial trimestral del DANE, sin sacrificar la coherencia estadística entre frecuencias.
- El tratamiento del PIB como variable de estado latente —y no como un dato interpolado mecánicamente— permite que la agregación trimestral opere como una restricción de medición exacta dentro del filtro de Kalman.

Consideraciones finales

- El MF-BVAR permite generar **nowcasts mensuales del PIB colombiano** explotando la información disponible antes de la publicación oficial trimestral del DANE, sin sacrificar la coherencia estadística entre frecuencias.
- El tratamiento del PIB como **variable de estado latente** — y no como un dato interpolado mecánicamente — permite que la agregación trimestral opere como una restricción de medición exacta dentro del filtro de Kalman.

Consideraciones finales

- El MF-BVAR permite generar **nowcasts mensuales del PIB colombiano** explotando la información disponible antes de la publicación oficial trimestral del DANE, sin sacrificar la coherencia estadística entre frecuencias.
- El tratamiento del PIB como **variable de estado latente** — y no como un dato interpolado mecánicamente — permite que la agregación trimestral opere como una restricción de medición exacta dentro del filtro de Kalman.

Consideraciones finales

- La evaluación puntual mostró un error absoluto de solo **0.40 %** en niveles, con el dato observado cayendo dentro de las bandas de credibilidad al 95 % tanto en crecimiento trimestral como anual.
- El enfoque bayesiano (prior de Minnesota + MNIW) resuelve el problema de sobreparametrización inherente a un VAR mensual con múltiples variables y rezagos, permitiendo estimar el sistema incluso con series relativamente cortas.

Consideraciones finales

- La evaluación puntual mostró un error absoluto de solo **0.40 %** en niveles, con el dato observado cayendo dentro de las bandas de credibilidad al 95 % tanto en crecimiento trimestral como anual.
- El enfoque bayesiano (prior de Minnesota + MNIW) resuelve el problema de sobreparametrización inherente a un VAR mensual con múltiples variables y rezagos, permitiendo estimar el sistema incluso con series relativamente cortas.

Consideraciones finales

- La evaluación puntual mostró un error absoluto de solo **0.40 %** en niveles, con el dato observado cayendo dentro de las bandas de credibilidad al 95 % tanto en crecimiento trimestral como anual.
- El enfoque bayesiano (prior de Minnesota + MNIW) resuelve el problema de sobreparametrización inherente a un VAR mensual con múltiples variables y rezagos, permitiendo estimar el sistema incluso con series relativamente cortas.

MUCHAS GRACIAS...!