Nowcasting del crecimiento económico en Colombia mediante modelos bayesianos de frecuencia mixta

Juan Diego Moreno Sánchez [1] Zeneth Olivero Tapia [2]
Jacobo Campo Robledo [1, 2]

[1]Universidad Externado de Colombia

[2]Universidad Católica de Colombia

Julio 14 de 2026

Contenido

1. Introducción - Problema
2. Marco Teórico y Revisión de Bibliografía
3. Datos y Metodología
   - Datos
   - Metodología
4. Estimaciones y Resultados
5. Consideraciones finales

Contenido

1. Introducción - Problema
2. Marco Teórico y Revisión de Bibliografía
3. Datos y Metodología
   - Datos
   - Metodología
4. Estimaciones y Resultados
5. Consideraciones finales

Contenido

1. Introducción - Problema
2. Marco Teórico y Revisión de Bibliografía
3. Datos y Metodología
   - Datos
   - Metodología
4. Estimaciones y Resultados
5. Consideraciones finales

Contenido

1. Introducción - Problema
2. Marco Teórico y Revisión de Bibliografía
3. Datos y Metodología
   - Datos
   - Metodología
4. Estimaciones y Resultados
5. Consideraciones finales

Contenido

1. Introducción - Problema
2. Marco Teórico y Revisión de Bibliografía
3. Datos y Metodología
   - Datos
   - Metodología
4. Estimaciones y Resultados
5. Consideraciones finales

Contenido

1. Introducción - Problema
2. Marco Teórico y Revisión de Bibliografía
3. Datos y Metodología
   - Datos
   - Metodología
4. Estimaciones y Resultados
5. Consideraciones finales

Contenido

1. Introducción - Problema
2. Marco Teórico y Revisión de Bibliografía
3. Datos y Metodología
   - Datos
   - Metodología
4. Estimaciones y Resultados
5. Consideraciones finales

Introducción - Problema

El Problema del Rezago y la Frecuencia

- **El Rezago Oficial vs. Nowcasting:** El PIB trimestral es clave para la toma de decisiones, pero el DANE lo publica con $\sim$45 días de rezago. El *nowcasting* soluciona esto estimando el PIB en tiempo real usando un amplio conjunto de variables mensuales (ISE, inflación, petróleo, TRM, etc.).
- **El Problema de la Frecuencia Constante:** Agregar artificialmente los datos mensuales para forzar la estimación de un modelo tradicional puramente trimestral desperdicia el flujo continuo de información y prohíbe actualizar el pronóstico mes a mes.

Introducción - Problema

El Problema del Rezago y la Frecuencia

- **El Rezago Oficial vs. Nowcasting:** El PIB trimestral es clave para la toma de decisiones, pero el DANE lo publica con $\sim$45 días de rezago. El *nowcasting* soluciona esto estimando el PIB en tiempo real usando un amplio conjunto de variables mensuales (ISE, inflación, petróleo, TRM, etc.).
- **El Problema de la Frecuencia Constante:** Agregar artificialmente los datos mensuales para forzar la estimación de un modelo tradicional puramente trimestral desperdicia el flujo continuo de información y prohíbe actualizar el pronóstico mes a mes.
- Solución vía Estado Latente: Se formula un modelo dinámico mensual completo, pero se trata al PIB como una *variable forzada* (una variable no observada en 2 de cada 3 meses). Así, el filtro de Kalman el desfasa sin perder ninguna dinámica de alta frecuencia.

Introducción - Problema

El Problema del Rezago y la Frecuencia

- **El Rezago Oficial vs. Nowcasting:** El PIB trimestral es clave para la toma de decisiones, pero el DANE lo publica con ∼45 días de rezago. El *nowcasting* soluciona esto estimando el PIB en tiempo real usando un amplio conjunto de variables mensuales (ISE, inflación, petróleo, TRM, etc.).
- **El Problema de la Frecuencia Constante:** Agregar artificialmente los datos mensuales para forzar la estimación de un modelo tradicional puramente trimestral desperdicia el flujo continuo de información y prohíbe actualizar el pronóstico mes a mes.
  - **Solución vía Estado Latente:** Se formula un modelo dinámico mensual completo, pero se trata al PIB como un *estado latente* (una variable no observada en 2 de cada 3 meses). Así se resuelve el desfase sin perder ninguna dinámica de alta frecuencia.

Introducción - Problema

El Problema del Rezago y la Frecuencia

- **El Rezago Oficial vs. Nowcasting:** El PIB trimestral es clave para la toma de decisiones, pero el DANE lo publica con ∼45 días de rezago. El *nowcasting* soluciona esto estimando el PIB en tiempo real usando un amplio conjunto de variables mensuales (ISE, inflación, petróleo, TRM, etc.).
- **El Problema de la Frecuencia Constante:** Agregar artificialmente los datos mensuales para forzar la estimación de un modelo tradicional puramente trimestral desperdicia el flujo continuo de información y prohíbe actualizar el pronóstico mes a mes.
- **Solución vía Estado Latente:** Se formula un modelo dinámico mensual completo, pero se trata al PIB como un *estado latente* (una variable no observada en 2 de cada 3 meses). Así se resuelve el desfase sin perder ninguna dinámica de alta frecuencia.

Introducción - Problema

El Problema del Rezago y la Frecuencia

- **El Rezago Oficial vs. Nowcasting:** El PIB trimestral es clave para la toma de decisiones, pero el DANE lo publica con $\sim$45 días de rezago. El *nowcasting* soluciona esto estimando el PIB en tiempo real usando un amplio conjunto de variables mensuales (ISE, inflación, petróleo, TRM, etc.).
- **El Problema de la Frecuencia Constante:** Agregar artificialmente los datos mensuales para forzar la estimación de un modelo tradicional puramente trimestral desperdicia el flujo continuo de información y prohíbe actualizar el pronóstico mes a mes.
- **Solución vía Estado Latente:** Se formula un modelo dinámico mensual completo, pero se trata al PIB como un ***estado latente*** (una variable no observada en 2 de cada 3 meses). Así se resuelve el desfase sin perder ninguna dinámica de alta frecuencia.

Introducción - Problema

¿Por qué un enfoque bayesiano?

- Un VAR mensual con varias variables y varios rezagos tiene muchos parámetros en relación con el número de observaciones disponibles (*sobreparametrización*) — estimarlo por MV/OLS sin restricciones produce coeficientes muy inestables y sobreajuste.
- El enfoque bayesiano permite introducir *priors* de contracción (*shrinkage*), el prior de Minnesota (Litterman, 1986).

Introducción - Problema

¿Por qué un enfoque bayesiano?

- Un VAR mensual con varias variables y varios rezagos tiene muchos parámetros en relación con el número de observaciones disponibles (*sobreparametrización*) — estimarlo por MV/OLS sin restricciones produce coeficientes muy inestables y sobreajuste.
- El enfoque bayesiano permite introducir *priors* de contracción (*shrinkage*), el prior de Minnesota (Litterman, 1986):

Introducción - Problema

¿Por qué un enfoque bayesiano?

- Un VAR mensual con varias variables y varios rezagos tiene muchos parámetros en relación con el número de observaciones disponibles (*sobreparametrización*) — estimarlo por MV/OLS sin restricciones produce coeficientes muy inestables y sobreajuste.
- El enfoque bayesiano permite introducir *priors* de contracción (*shrinkage*), el prior de Minnesota (Litterman, 1986):
  - Regulariza los coeficientes hacia una estructura parsimoniosa (ej. paseo aleatorio) sin eliminar variables arbitrariamente
  - Permite incluir más variables e indicadores de los que un VAR clásico toleraría con series relativamente cortas,
  - Mejora la precisión fuera de muestra frente a alternativas no restringidas (Bańbura, Giannone y Reichlin (2010)).

Introducción - Problema

¿Por qué un enfoque bayesiano?

- Un VAR mensual con varias variables y varios rezagos tiene muchos parámetros en relación con el número de observaciones disponibles (*sobreparametrización*) — estimarlo por MV/OLS sin restricciones produce coeficientes muy inestables y sobreajuste.
- El enfoque bayesiano permite introducir *priors* de contracción (*shrinkage*), el prior de Minnesota (Litterman, 1986):
  - Regulariza los coeficientes hacia una estructura parsimoniosa (ej. paseo aleatorio) sin eliminar variables arbitrariamente
  - Permite incluir más variables e indicadores de los que un VAR clásico toleraría con series relativamente cortas,
  - Mejora la precisión fuera de muestra frente a alternativas no restringidas (Bańbura, Giannone y Reichlin (2010)).

Introducción - Problema

¿Por qué un enfoque bayesiano?

- Un VAR mensual con varias variables y varios rezagos tiene muchos parámetros en relación con el número de observaciones disponibles (*sobreparametrización*) — estimarlo por MV/OLS sin restricciones produce coeficientes muy inestables y sobreajuste.
- El enfoque bayesiano permite introducir *priors* de contracción (*shrinkage*), el prior de Minnesota (Litterman, 1986):
  - Regulariza los coeficientes hacia una estructura parsimoniosa (ej. paseo aleatorio) sin eliminar variables arbitrariamente
  - Permite incluir más variables e indicadores de los que un VAR clásico toleraría con series relativamente cortas,
  - Mejora la precisión fuera de muestra frente a alternativas no restringidas (Bańbura, Giannone y Reichlin (2010)).

Introducción - Problema

¿Por qué un enfoque bayesiano?

- Un VAR mensual con varias variables y varios rezagos tiene muchos parámetros en relación con el número de observaciones disponibles (*sobreparametrización*) — estimarlo por MV/OLS sin restricciones produce coeficientes muy inestables y sobreajuste.
- El enfoque bayesiano permite introducir *priors* de contracción (*shrinkage*), el prior de Minnesota (Litterman, 1986):
  - Regulariza los coeficientes hacia una estructura parsimoniosa (ej. paseo aleatorio) sin eliminar variables arbitrariamente
  - Permite incluir más variables e indicadores de los que un VAR clásico toleraría con series relativamente cortas,
  - Mejora la precisión fuera de muestra frente a alternativas no restringidas (Bańbura, Giannone y Reichlin (2010)).

Introducción - Problema

¿Por qué un enfoque bayesiano?

- Además, el marco bayesiano entrega una distribución *posterior* completa del pronóstico (no solo un punto), lo que permite cuantificar la incertidumbre alrededor del **nowcast** — información valiosa para el análisis de riesgo y la comunicación de política.
- El tratamiento de frecuencia mixta (*variable trimestral parcialmente observada*) se resuelve de forma natural dentro de una representación de espacio de estados (**filtro de Kalman**), que es el marco estándar para inferencia bayesiana en modelos dinámicos.

Introducción - Problema

¿Por qué un enfoque bayesiano?

- Además, el marco bayesiano entrega una distribución *posterior* completa del pronóstico (no solo un punto), lo que permite cuantificar la incertidumbre alrededor del **nowcast** — información valiosa para el análisis de riesgo y la comunicación de política.
- El tratamiento de frecuencia mixta (*variable trimestral parcialmente observada*) se resuelve de forma natural dentro de una representación de espacio de estados (**filtro de Kalman**), que es el marco estándar para inferencia bayesiana en modelos dinámicos.

Introducción - Problema

¿Por qué un enfoque bayesiano?

- Además, el marco bayesiano entrega una distribución *posterior* completa del pronóstico (no solo un punto), lo que permite cuantificar la incertidumbre alrededor del **nowcast** — información valiosa para el análisis de riesgo y la comunicación de política.
- El tratamiento de frecuencia mixta (*variable trimestral parcialmente observada*) se resuelve de forma natural dentro de una representación de espacio de estados (**filtro de Kalman**), que es el marco estándar para inferencia bayesiana en modelos dinámicos.

Introducción - Problema

Objetivo general

Proponer y estimar un modelo de *nowcasting* del crecimiento económico de Colombia mediante un Bayesian Mixed-Frequency VAR (MF-BVAR), que permita actualizar el pronóstico del PIB trimestral a partir de indicadores mensuales de actividad real, precios, condiciones financieras y sector externo.

Marco Teórico y Revisión de Bibliografía

- Giannone, Reichlin y Small (2008): definen el nowcasting como la actualización continua del pronóstico del trimestre corriente conforme llega nueva información.
- Mariano y Murasawa (2003): proponen el índice coincidente basado en series mensuales y trimestrales — base de la identidad de agregación en un MF-BVAR.
- Kuzin, Marcellino y Schumacher (2011): comparan MIDAS vs. VAR de frecuencia mixta para nowcasting del PIB de la eurozona.
- Carriero, Clark y Marcellino (2015): extienden el MF-BVAR con volatilidad estocástica para pronóstico en tiempo real.

Marco Teórico y Revisión de Bibliografía

- Giannone, Reichlin y Small (2008): definen el nowcasting como la actualización continua del pronóstico del trimestre corriente conforme llega nueva información.
- Mariano y Murasawa (2003): proponen el índice coincidente basado en series mensuales y trimestrales — base de la identidad de agregación en un MF-BVAR.
- Kuzin, Marcellino y Schumacher (2011): comparan MIDAS vs. VAR de frecuencia mixta para nowcasting del PIB de la eurozona.
- Carriero, Clark y Marcellino (2015): extienden el MF-BVAR con volatilidad estocástica para pronóstico en tiempo real.

Marco Teórico y Revisión de Bibliografía

- Giannone, Reichlin y Small (2008): definen el nowcasting como la actualización continua del pronóstico del trimestre corriente conforme llega nueva información.
- Mariano y Murasawa (2003): proponen el índice coincidente basado en series mensuales y trimestrales — base de la identidad de agregación en un MF-BVAR.
- Kuzin, Marcellino y Schumacher (2011): comparan MIDAS vs. VAR de frecuencia mixta para nowcasting del PIB de la eurozona.
- Carriero, Clark y Marcellino (2015): extienden el MF-BVAR con volatilidad estocástica para pronóstico en tiempo real.

Marco Teórico y Revisión de Bibliografía

- Giannone, Reichlin y Small (2008): definen el nowcasting como la actualización continua del pronóstico del trimestre corriente conforme llega nueva información.
- Mariano y Murasawa (2003): proponen el índice coincidente basado en series mensuales y trimestrales — base de la identidad de agregación en un MF-BVAR.
- Kuzin, Marcellino y Schumacher (2011): comparan MIDAS vs. VAR de frecuencia mixta para nowcasting del PIB de la eurozona.
- Carriero, Clark y Marcellino (2015): extienden el MF-BVAR con volatilidad estocástica para pronóstico en tiempo real.

Marco Teórico y Revisión de Bibliografía

- Litterman (1986): origen del *prior* de Minnesota.
- Banbura, Giannone y Reichlin (2010): BVAR grandes con contracción — muestran que permite incluir muchas variables sin perder precisión predictiva.
- Schorfheide y Song (2015): desarrollan el marco de pronóstico en tiempo real que combina variables mensuales y trimestrales en una estructura VAR de frecuencia mixta.

Marco Teórico y Revisión de Bibliografía

- Litterman (1986): origen del *prior* de Minnesota.
- Banbura, Giannone y Reichlin (2010): BVAR grandes con contracción — muestran que permite incluir muchas variables sin perder precisión predictiva.
- Schorfheide y Song (2015): desarrollan el marco de pronóstico en tiempo real que combina variables mensuales y trimestrales en una estructura VAR de frecuencia mixta.

Marco Teórico y Revisión de Bibliografía

- Litterman (1986): origen del *prior* de Minnesota.
- Banbura, Giannone y Reichlin (2010): BVAR grandes con contracción — muestran que permite incluir muchas variables sin perder precisión predictiva.
- Schorfheide y Song (2015): desarrollan el marco de pronóstico en tiempo real que combina variables mensuales y trimestrales en una estructura VAR de frecuencia mixta.

Datos

Se construye un sistema de frecuencia mixta con **9 variables** para Colombia, combinando una serie trimestral objetivo y ocho indicadores mensuales de actividad real, precios, condiciones monetarias y sector externo.

Variable	Frecuencia	Fuente	Rol
PIB real	Trimestral	DANE	Variable objetivo
ISE	Mensual	DANE	Actividad económica agregada
IPI (Producción industrial)	Mensual	DANE	Sector manufacturero
Tasa de desempleo	Mensual	DANE	Mercado laboral
Inflación (IPC)	Mensual	DANE	Precios
TRM	Mensual	Banco de la República	Sector externo / financiero
Tasa de política monetaria	Mensual	Banco de la República	Condiciones monetarias
Petróleo (Brent)	Mensual	Mercados internacionales	Choque externo (términos de intercambio)
IEC	Mensual	Fedesarrollo	Expectativas

Datos

Se construye un sistema de frecuencia mixta con **9 variables** para Colombia, combinando una serie trimestral objetivo y ocho indicadores mensuales de actividad real, precios, condiciones monetarias y sector externo.

Variable	**Frecuencia**	**Fuente**	**Rol**
PIB real	Trimestral	DANE	Variable objetivo
ISE	Mensual	DANE	Actividad económica agregada
IPI (Producción industrial)	Mensual	DANE	Sector manufacturero
Tasa de desempleo	Mensual	DANE	Mercado laboral
Inflación (IPC)	Mensual	DANE	Precios
TRM	Mensual	Banco de la República	Sector externo / financiero
Tasa de política monetaria	Mensual	Banco de la República	Condiciones monetarias
Petróleo (Brent)	Mensual	Mercados internacionales	Choque externo (términos de intercambio)
IEC	Mensual	Fedesarrollo	Expectativas

Datos

Muestra y Transformaciones

- **Muestra histórica**: 2014–2026 (hasta Abril).
- **Muestra de nowcasting**: 2021–2026 (submuestra reciente, usada para el ejercicio de pronóstico en tiempo real).
- Todas las series mensuales se emplean desestacionalizadas.
- Las variables se modelan **en niveles**; la no estacionariedad se controla directamente a través del *prior* de Minnesota, que impone la hipótesis de *random walk* sobre el primer rezago propio de cada variable.

Datos

Muestra y Transformaciones

- **Muestra histórica**: 2014–2026 (hasta Abril).
- **Muestra de nowcasting**: 2021–2026 (submuestra reciente, usada para el ejercicio de pronóstico en tiempo real).
- Todas las series mensuales se emplean desestacionalizadas.
- Las variables se modelan **en niveles**; la no estacionariedad se controla directamente a través del *prior* de Minnesota, que impone la hipótesis de *random walk* sobre el primer rezago propio de cada variable.

Datos

Muestra y Transformaciones

- **Muestra histórica**: 2014–2026 (hasta Abril).
- **Muestra de nowcasting**: 2021–2026 (submuestra reciente, usada para el ejercicio de pronóstico en tiempo real).
- Todas las series mensuales se emplean desestacionalizadas.
- Las variables se modelan **en niveles**; la no estacionariedad se controla directamente a través del *prior* de Minnesota, que impone la hipótesis de *random walk* sobre el primer rezago propio de cada variable.

Datos

Muestra y Transformaciones

- **Muestra histórica**: 2014–2026 (hasta Abril).
- **Muestra de nowcasting**: 2021–2026 (submuestra reciente, usada para el ejercicio de pronóstico en tiempo real).
- Todas las series mensuales se emplean desestacionalizadas.
- Las variables se modelan **en niveles**; la no estacionariedad se controla directamente a través del *prior* de Minnesota, que impone la hipótesis de *random walk* sobre el primer rezago propio de cada variable.

Metodología

Panorama General

El modelo se estima en tres etapas:

1. **Especificación**: VAR mensual en forma de espacio de estados, con el PIB trimestral como variable parcialmente observada (Schorfheide y Song, 2015).
2. **Estimación bayesiana**: muestreador de Gibbs, combinando simulación de estados (Carter-Kohn, 1994) y actualización de parámetros bajo *prior* de Minnesota.
3. **Pronóstico**: [illegible]

Metodología

Panorama General

El modelo se estima en tres etapas:

1. **Especificación**: VAR mensual en forma de espacio de estados, con el PIB trimestral como variable parcialmente observada (Schorfheide y Song, 2015).
2. **Estimación bayesiana**: muestreador de Gibbs, combinando simulación de estados (Carter-Kohn, 1994) y actualización de parámetros bajo *prior* de Minnesota.

Metodología

Panorama General

El modelo se estima en tres etapas:

1. **Especificación**: VAR mensual en forma de espacio de estados, con el PIB trimestral como variable parcialmente observada (Schorfheide y Song, 2015).
2. **Estimación bayesiana**: muestreador de Gibbs, combinando simulación de estados (Carter-Kohn, 1994) y actualización de parámetros bajo *prior* de Minnesota.
3. **Proyección**: densidad predictiva conjunta del PIB mensual latente, agregada de forma consistente al horizonte trimestral de interés.

Metodología

Panorama General

El modelo se estima en tres etapas:

1. **Especificación**: VAR mensual en forma de espacio de estados, con el PIB trimestral como variable parcialmente observada (Schorfheide y Song, 2015).
2. **Estimación bayesiana**: muestreador de Gibbs, combinando simulación de estados (Carter-Kohn, 1994) y actualización de parámetros bajo *prior* de Minnesota.
3. **Proyección**: densidad predictiva conjunta del PIB mensual latente, agregada de forma consistente al horizonte trimestral de interés.

Metodología

Panorama General

El modelo se estima en tres etapas:

1. **Especificación**: VAR mensual en forma de espacio de estados, con el PIB trimestral como variable parcialmente observada (Schorfheide y Song, 2015).
2. **Estimación bayesiana**: muestreador de Gibbs, combinando simulación de estados (Carter-Kohn, 1994) y actualización de parámetros bajo *prior* de Minnesota.
3. **Proyección**: densidad predictiva conjunta del PIB mensual latente, agregada de forma consistente al horizonte trimestral de interés.

Metodología

Panorama General

El modelo se estima en tres etapas:

1. **Especificación**: VAR mensual en forma de espacio de estados, con el PIB trimestral como variable parcialmente observada (Schorfheide y Song, 2015).
2. **Estimación bayesiana**: muestreador de Gibbs, combinando simulación de estados (Carter-Kohn, 1994) y actualización de parámetros bajo *prior* de Minnesota.
3. **Proyección**: densidad predictiva conjunta del PIB mensual latente, agregada de forma consistente al horizonte trimestral de interés.

Metodología

Dinámica del Sistema (Ecuación de Transición)

Sea $x_t = [x'_{m,t}, x'_{q,t}]'$ un vector $n \times 1$ de variables macroeconómicas. La dinámica mensual evoluciona según un proceso autorregresivo:

$$Z_t = F(\Phi)Z_{t-1} + F_c(\Phi) + V_t, \quad V_t \sim \text{i.i.d. } N(0, \Omega(\Sigma))$$

Donde la matriz compañera $F(\Phi)$ y la matriz singular de covarianza $\Omega(\Sigma)$ asimilan los rezagos del sistema original:

$$F(\Phi) = \begin{bmatrix} \Phi_1 & \Phi_2 & \cdots & \Phi_p \\ I_{n(p-1)} & & 0_{n(p-1)\times n} & \end{bmatrix}, \quad \Omega(\Sigma) = \begin{bmatrix} \Sigma & 0 \\ 0 & 0 \end{bmatrix}$$

Metodología

Dinámica del Sistema (Ecuación de Transición)

Sea $x_t = [x'_{m,t}, x'_{q,t}]'$ un vector $n \times 1$ de variables macroeconómicas. La dinámica mensual evoluciona según un proceso autorregresivo:

$$Z_t = F(\Phi)Z_{t-1} + F_c(\Phi) + V_t, \quad V_t \sim \text{i.i.d. } N(0, \Omega(\Sigma))$$

Donde la matriz compañera $F(\Phi)$ y la matriz singular de covarianza $\Omega(\Sigma)$ asimilan los rezagos del sistema original:

$$F(\Phi) = \begin{bmatrix} \Phi_1 & \Phi_2 & \cdots & \Phi_p \\ I_{n(p-1)} & & 0_{n(p-1)\times n} & \end{bmatrix}, \quad \Omega(\Sigma) = \begin{bmatrix} \Sigma & 0 \\ 0 & 0 \end{bmatrix}$$

Metodología

Dinámica del Sistema (Ecuación de Transición)

Sea $x_t = [x'_{m,t}, x'_{q,t}]'$ un vector $n \times 1$ de variables macroeconómicas. La dinámica mensual evoluciona según un proceso autorregresivo:

$$Z_t = F(\Phi)Z_{t-1} + F_c(\Phi) + V_t, \quad V_t \sim \text{i.i.d. } N(0, \Omega(\Sigma))$$

Donde la matriz compañera $F(\Phi)$ y la matriz singular de covarianza $\Omega(\Sigma)$ asimilan los rezagos del sistema original:

$$F(\Phi) = \begin{bmatrix} \Phi_1 & \Phi_2 & \cdots & \Phi_p \\ I_{n(p-1)} & & 0_{n(p-1)\times n} & \end{bmatrix}, \quad \Omega(\Sigma) = \begin{bmatrix} \Sigma & 0 \\ 0 & 0 \end{bmatrix}$$

Metodología

Dinámica del Sistema (Ecuación de Transición)

Sea $x_t = [x'_{m,t}, x'_{q,t}]'$ un vector $n \times 1$ de variables macroeconómicas. La dinámica mensual evoluciona según un proceso autorregresivo:

$$Z_t = F(\Phi)Z_{t-1} + F_c(\Phi) + V_t, \quad V_t \sim \text{i.i.d. } N(0, \Omega(\Sigma))$$

Donde la matriz compañera $F(\Phi)$ y la matriz singular de covarianza $\Omega(\Sigma)$ asimilan los rezagos del sistema original:

$$F(\Phi) = \begin{bmatrix} \Phi_1 & \Phi_2 & \cdots & \Phi_p \\ I_{n(p-1)} & & 0_{n(p-1)\times n} & \end{bmatrix}, \quad \Omega(\Sigma) = \begin{bmatrix} \Sigma & 0 \\ 0 & 0 \end{bmatrix}$$

Metodología

Ecuación de Medición y Restricción Aditiva

Para relacionar el vector mensual latente con los datos oficiales y solucionar el problema de desfase de publicación (*ragged edge*):

$$Y_t^{obs} = M_t \Lambda Z_t$$

Donde M_t es una matriz variante en el tiempo que apaga las celdas vacías (NA) en el mes t, y Λ es la matriz de agregación temporal.

Restricción Aditiva del PIB

Como el PIB se modela en niveles, la agregación trimestral impone una restricción determinística en el Filtro de Kalman:

$$PIB_{Q,t} = PIB^*_{M,t} + PIB^*_{M,t-1} + PIB^*_{M,t-2}$$

Metodología

Ecuación de Medición y Restricción Aditiva

Para relacionar el vector mensual latente con los datos oficiales y solucionar el problema de desfase de publicación (*ragged edge*):

$$Y_t^{obs} = M_t \Lambda Z_t$$

Donde M_t es una matriz variante en el tiempo que apaga las celdas vacías (NA) en el mes t, y Λ es la matriz de agregación temporal.

Restricción Aditiva del PIB

Como el PIB se modela en niveles, la agregación trimestral impone una restricción determinística en el Filtro de Kalman:

$$PIB_{Q,t} = PIB^*_{M,t} + PIB^*_{M,t-1} + PIB^*_{M,t-2}$$

Metodología

Ecuación de Medición y Restricción Aditiva

Para relacionar el vector mensual latente con los datos oficiales y solucionar el problema de desfase de publicación (*ragged edge*):

$$Y_t^{obs} = M_t \Lambda Z_t$$

Donde M_t es una matriz variante en el tiempo que apaga las celdas vacías (NA) en el mes t, y Λ es la matriz de agregación temporal.

Restricción Aditiva del PIB

Como el PIB se modela en niveles, la agregación trimestral impone una restricción determinística en el Filtro de Kalman:

$$PIB_{Q,t} = PIB^*_{M,t} + PIB^*_{M,t-1} + PIB^*_{M,t-2}$$

Metodología

Ecuación de Medición y Restricción Aditiva

Para relacionar el vector mensual latente con los datos oficiales y solucionar el problema de desfase de publicación (*ragged edge*):

$$Y_t^{obs} = M_t \Lambda Z_t$$

Donde M_t es una matriz variante en el tiempo que apaga las celdas vacías (NA) en el mes t, y Λ es la matriz de agregación temporal.

Restricción Aditiva del PIB

Como el PIB se modela en niveles, la agregación trimestral impone una restricción determinística en el Filtro de Kalman:

$$PIB_{Q,t} = PIB^*_{M,t} + PIB^*_{M,t-1} + PIB^*_{M,t-2}$$

Metodología

Ecuación de Medición y Restricción Aditiva

Para relacionar el vector mensual latente con los datos oficiales y solucionar el problema de desfase de publicación (*ragged edge*):

$$Y_t^{obs} = M_t \Lambda Z_t$$

Donde M_t es una matriz variante en el tiempo que apaga las celdas vacías (NA) en el mes t, y Λ es la matriz de agregación temporal.

Restricción Aditiva del PIB

Como el PIB se modela en niveles, la agregación trimestral impone una restricción determinística en el Filtro de Kalman:

$$PIB_{Q,t} = PIB^*_{M,t} + PIB^*_{M,t-1} + PIB^*_{M,t-2}$$

Metodología

Muestreo de Gibbs (Simulación de Estados y Parámetros)

La estimación del modelo iterará 20,000 veces sobre dos pasos:

1. **Simulación de Estados (Carter-Kohn, 1994)**: Sorteo de la trayectoria $Z_{1:T}$ condicionado a los parámetros fijos:

$$p(Z_{1:T} \mid Y_{1:T}^{obs}, \psi, \Sigma) \propto p(Z_0) \prod_{t=1}^{T} p(Y_t^{obs} \mid Z_t) p(Z_t \mid Z_{t-1}, \psi, \Sigma)$$

Metodología

Muestreo de Gibbs (Simulación de Estados y Parámetros)

La estimación del modelo iterará 20,000 veces sobre dos pasos:

1. **Simulación de Estados (Carter-Kohn, 1994)**: Sorteo de la trayectoria $Z_{1:T}$ condicionado a los parámetros fijos:

$$p(Z_{1:T} \mid Y_{1:T}^{obs}, \Phi, \Sigma) \propto p(Z_0) \prod_{t=1}^{T} p(Y_t^{obs} \mid Z_t) p(Z_t \mid Z_{t-1}, \Phi, \Sigma)$$

Metodología

Muestreo de Gibbs (Simulación de Estados y Parámetros)

La estimación del modelo iterará 20,000 veces sobre dos pasos:

1. **Simulación de Estados (Carter-Kohn, 1994)**: Sorteo de la trayectoria $Z_{1:T}$ condicionado a los parámetros fijos:

$$p(Z_{1:T} \mid Y_{1:T}^{obs}, \Phi, \Sigma) \propto p(Z_0) \prod_{t=1}^{T} p(Y_t^{obs} \mid Z_t) p(Z_t \mid Z_{t-1}, \Phi, \Sigma)$$

2. **Simulación de Parámetros (*Prior* de Minnesota)**: Sorteo de (Φ, Σ) condicionado al vector de estados simulado:

$$p(\Phi, \Sigma \mid Z_{1:T}, Y_{1:T}^{obs}) \propto p(\Phi, \Sigma) \prod_{t=1}^{T} p(Z_t \mid Z_{t-1}, \Phi, \Sigma)$$

Metodología

Muestreo de Gibbs (Simulación de Estados y Parámetros)

La estimación del modelo iterará 20,000 veces sobre dos pasos:

1. **Simulación de Estados (Carter-Kohn, 1994)**: Sorteo de la trayectoria $Z_{1:T}$ condicionado a los parámetros fijos:

$$p(Z_{1:T} \mid Y_{1:T}^{obs}, \Phi, \Sigma) \propto p(Z_0) \prod_{t=1}^{T} p(Y_t^{obs} \mid Z_t) p(Z_t \mid Z_{t-1}, \Phi, \Sigma)$$

2. **Simulación de Parámetros (*Prior* de Minnesota)**: Sorteo de (Φ, Σ) condicionado al vector de estados simulado:

$$p(\Phi, \Sigma \mid Y_{1:T}^{obs}, Z_{1:T}) \sim MNIW(\Phi, \Psi, \Sigma, \nu)$$

Metodología

Muestreo de Gibbs (Simulación de Estados y Parámetros)

La estimación del modelo iterará 20,000 veces sobre dos pasos:

1. **Simulación de Estados (Carter-Kohn, 1994)**: Sorteo de la trayectoria $Z_{1:T}$ condicionado a los parámetros fijos:

$$p(Z_{1:T} \mid Y_{1:T}^{obs}, \Phi, \Sigma) \propto p(Z_0) \prod_{t=1}^{T} p(Y_t^{obs} \mid Z_t) p(Z_t \mid Z_{t-1}, \Phi, \Sigma)$$

2. **Simulación de Parámetros (*Prior* de Minnesota)**: Sorteo de (Φ, Σ) condicionado al vector de estados simulado:

$$p(\Phi, \Sigma \mid Y_{1:T}^{obs}, Z_{1:T}) \sim MNIW(\bar{\Phi}, \bar{\Psi}, \bar{\Sigma}, \bar{\nu})$$

Metodología

Muestreo de Gibbs (Simulación de Estados y Parámetros)

La estimación del modelo iterará 20,000 veces sobre dos pasos:

1. **Simulación de Estados (Carter-Kohn, 1994)**: Sorteo de la trayectoria $Z_{1:T}$ condicionado a los parámetros fijos:

$$p(Z_{1:T} \mid Y_{1:T}^{obs}, \Phi, \Sigma) \propto p(Z_0) \prod_{t=1}^{T} p(Y_t^{obs} \mid Z_t) p(Z_t \mid Z_{t-1}, \Phi, \Sigma)$$

2. **Simulación de Parámetros (*Prior* de Minnesota)**: Sorteo de (Φ, Σ) condicionado al vector de estados simulado:

$$p(\Phi, \Sigma \mid Y_{1:T}^{obs}, Z_{1:T}) \sim MNIW(\bar{\Phi}, \bar{\Psi}, \bar{\Sigma}, \bar{\nu})$$

Metodología

Muestreo de Gibbs (Simulación de Estados y Parámetros)

La estimación del modelo iterará 20,000 veces sobre dos pasos:

1. **Simulación de Estados (Carter-Kohn, 1994)**: Sorteo de la trayectoria $Z_{1:T}$ condicionado a los parámetros fijos:

$$p(Z_{1:T} \mid Y_{1:T}^{obs}, \Phi, \Sigma) \propto p(Z_0) \prod_{t=1}^{T} p(Y_t^{obs} \mid Z_t) p(Z_t \mid Z_{t-1}, \Phi, \Sigma)$$

2. **Simulación de Parámetros (*Prior* de Minnesota)**: Sorteo de (Φ, Σ) condicionado al vector de estados simulado:

$$p(\Phi, \Sigma \mid Y_{1:T}^{obs}, Z_{1:T}) \sim MNIW(\bar{\Phi}, \bar{\Psi}, \bar{\Sigma}, \bar{\nu})$$

Metodología

Pronóstico: Densidad Predictiva Posterior

Finalmente, en el horizonte de pronóstico $T+1, \ldots, T+H$, el PIB mensual latente se proyecta marginalizando la incertidumbre:

$$p(Z_{T+1:T+H} \mid Y_{1:T}^{obs}) = \int p(Z_{T+1:T+H} \mid Z_T, \Phi, \Sigma) p(\Phi, \Sigma \mid Datos)\, d(\Phi, \Sigma)$$

- Esta integral se aproxima mediante el remuestreo de las trayectorias de Montecarlo (descartando el *burn-in*).

Metodología

Pronóstico: Densidad Predictiva Posterior

Finalmente, en el horizonte de pronóstico $T+1,\ldots,T+H$, el PIB mensual latente se proyecta marginalizando la incertidumbre:

$$p(Z_{T+1:T+H} \mid Y_{1:T}^{obs}) = \int p(Z_{T+1:T+H} \mid Z_T, \Phi, \Sigma) p(\Phi, \Sigma \mid Datos)\, d(\Phi, \Sigma)$$

- Esta integral se aproxima mediante el remuestreo de las trayectorias de Montecarlo (descartando el *burn-in*).
- Genera estimaciones puntuales (la mediana) y bandas de incertidumbre o credibilidad (ej. 95 %).

Metodología

Pronóstico: Densidad Predictiva Posterior

Finalmente, en el horizonte de pronóstico $T+1,\ldots,T+H$, el PIB mensual latente se proyecta marginalizando la incertidumbre:

$$p(Z_{T+1:T+H} \mid Y_{1:T}^{obs}) = \int p(Z_{T+1:T+H} \mid Z_T, \Phi, \Sigma) p(\Phi, \Sigma \mid Datos)\, d(\Phi, \Sigma)$$

- Esta integral se aproxima mediante el remuestreo de las trayectorias de Montecarlo (descartando el *burn-in*).
- Genera estimaciones puntuales (la mediana) y bandas de incertidumbre o credibilidad (ej. 95 %).

Metodología

Pronóstico: Densidad Predictiva Posterior

Finalmente, en el horizonte de pronóstico $T+1,\ldots,T+H$, el PIB mensual latente se proyecta marginalizando la incertidumbre:

$$p(Z_{T+1:T+H} \mid Y_{1:T}^{obs}) = \int p(Z_{T+1:T+H} \mid Z_T, \Phi, \Sigma) p(\Phi, \Sigma \mid Datos)\, d(\Phi, \Sigma)$$

- Esta integral se aproxima mediante el remuestreo de las trayectorias de Montecarlo (descartando el *burn-in*).
- Genera estimaciones puntuales (la mediana) y bandas de incertidumbre o credibilidad (ej. 95 %).

Metodología

Calibración y Diagnósticos de Convergencia MCMC

- **Prior de Minnesota**: $\lambda_1 = 0{,}09$. Controla la contracción de los coeficientes hacia la hipótesis de *random walk* en cada variable.
- **Simulaciones**: 20,000 (*draws*), 10,000 calentamiento (*burn-in*).
- **Especificación de rezagos**: $p = 6$ en la muestra histórica completa; $p = 4$ en la submuestra de nowcasting (2021–2026), para evitar singularidad en la matriz de covarianza del prior.
- **Tamaño de muestra efectivo (ESS)**:
- Un ESS alto (*relativo*) indica baja autocorrelación en la cadena y buena mezcla del muestreador de Gibbs (convergencia adecuada).

Metodología

Calibración y Diagnósticos de Convergencia MCMC

- **Prior de Minnesota**: $\lambda_1 = 0{,}09$. Controla la contracción de los coeficientes hacia la hipótesis de *random walk* en cada variable.
- **Simulaciones**: 20,000 (*draws*), 10,000 calentamiento (*burn-in*).
- **Especificación de rezagos**: $p = 6$ en la muestra histórica completa; $p = 4$ en la submuestra de nowcasting (2021–2026), para evitar singularidad en la matriz de covarianza del prior.
- **Tamaño de muestra efectivo (ESS)**:
  - Un ESS alto (*relativo*) indica baja autocorrelación en la cadena y buena mezcla del muestreador de Gibbs (convergencia adecuada).

Metodología

Calibración y Diagnósticos de Convergencia MCMC

- **Prior de Minnesota**: $\lambda_1 = 0{,}09$. Controla la contracción de los coeficientes hacia la hipótesis de *random walk* en cada variable.
- **Simulaciones**: 20,000 (*draws*), 10,000 calentamiento (*burn-in*).
- **Especificación de rezagos**: $p = 6$ en la muestra histórica completa; $p = 4$ en la submuestra de nowcasting (2021–2026), para evitar singularidad en la matriz de covarianza del prior.
- **Tamaño de muestra efectivo (ESS)**:
  - Muestra histórica ($p = 6$): ESS $= 3{,}989{,}74$
  - Muestra de nowcasting ($p = 4$): ESS $= 1{,}914{,}56$
- Un ESS alto (*relativo*) indica baja autocorrelación en la cadena y buena mezcla del muestreador de Gibbs (convergencia adecuada).

Metodología

Calibración y Diagnósticos de Convergencia MCMC

- **Prior de Minnesota**: $\lambda_1 = 0{,}09$. Controla la contracción de los coeficientes hacia la hipótesis de *random walk* en cada variable.
- **Simulaciones**: 20,000 (*draws*), 10,000 calentamiento (*burn-in*).
- **Especificación de rezagos**: $p = 6$ en la muestra histórica completa; $p = 4$ en la submuestra de nowcasting (2021–2026), para evitar singularidad en la matriz de covarianza del prior.
- **Tamaño de muestra efectivo (ESS)**:
  - Muestra histórica ($p = 6$): ESS = 3,989,74
  - Muestra de nowcasting ($p = 4$): ESS = 1,914,61
- Un ESS alto (*relativo*) indica baja autocorrelación en la cadena y buena mezcla del muestreador de Gibbs (convergencia adecuada).

Metodología

Calibración y Diagnósticos de Convergencia MCMC

- **Prior de Minnesota**: $\lambda_1 = 0{,}09$. Controla la contracción de los coeficientes hacia la hipótesis de *random walk* en cada variable.
- **Simulaciones**: 20,000 (*draws*), 10,000 calentamiento (*burn-in*).
- **Especificación de rezagos**: $p = 6$ en la muestra histórica completa; $p = 4$ en la submuestra de nowcasting (2021–2026), para evitar singularidad en la matriz de covarianza del prior.
- **Tamaño de muestra efectivo (ESS)**:
  - Muestra histórica ($p = 6$): ESS = 3,989,74
  - Muestra de nowcasting ($p = 4$): ESS = 1,914,61
- Un ESS alto (*relativo*) indica baja autocorrelación en la cadena y buena mezcla del muestreador de Gibbs (convergencia adecuada).

Metodología

Calibración y Diagnósticos de Convergencia MCMC

- **Prior de Minnesota**: $\lambda_1 = 0{,}09$. Controla la contracción de los coeficientes hacia la hipótesis de *random walk* en cada variable.
- **Simulaciones**: 20,000 (*draws*), 10,000 calentamiento (*burn-in*).
- **Especificación de rezagos**: $p = 6$ en la muestra histórica completa; $p = 4$ en la submuestra de nowcasting (2021–2026), para evitar singularidad en la matriz de covarianza del prior.
- **Tamaño de muestra efectivo (ESS)**:
  - Muestra histórica ($p = 6$): ESS = 3,989,74
  - Muestra de nowcasting ($p = 4$): ESS = 1,914,61
- Un ESS alto (*relativo*) indica baja autocorrelación en la cadena y buena mezcla del muestreador de Gibbs (convergencia adecuada).

Metodología

Calibración y Diagnósticos de Convergencia MCMC

- **Prior de Minnesota**: $\lambda_1 = 0{,}09$. Controla la contracción de los coeficientes hacia la hipótesis de *random walk* en cada variable.
- **Simulaciones**: 20,000 (*draws*), 10,000 calentamiento (*burn-in*).
- **Especificación de rezagos**: $p = 6$ en la muestra histórica completa; $p = 4$ en la submuestra de nowcasting (2021–2026), para evitar singularidad en la matriz de covarianza del prior.
- **Tamaño de muestra efectivo (ESS)**:
  - Muestra histórica ($p = 6$): ESS = 3,989,74
  - Muestra de nowcasting ($p = 4$): ESS = 1,914,61
- Un ESS alto (*relativo*) indica baja autocorrelación en la cadena y buena mezcla del muestreador de Gibbs (convergencia adecuada).

Estimaciones y Resultados

Pronóstico para el Segundo Trimestre de 2026 (Q2)

Proyección del modelo MF-BVAR para el trimestre evaluado:

Métrica / Indicador	Mediana BVAR	Intervalo de Credibilidad (95 %)
PIB real (niveles, MM)	**262,181.0**	[256,930.0 a 267,471.0]
Crec. Intertrimestral (Q2 vs Q1-2026)	**+1.31 %**	[-0.72 % a +3.36 %]
Crec. Interanual (Q2-2026 vs Q2-2025)	**+3.48 %**	[+1.41 % a +5.57 %]

Se estima un crecimiento intertrimestral del **+1.31 %** y un crecimiento interanual del **+3.48 %** para el Q2-2026.

Estimaciones y Resultados

Pronóstico para el Segundo Trimestre de 2026 (Q2)

Proyección del modelo MF-BVAR para el trimestre evaluado:

Métrica / Indicador	**Mediana BVAR**	**Intervalo de Credibilidad (95 %)**
PIB real (niveles, MM)	**262,181.0**	[256,930.0 a 267,471.0]
Crec. Intertrimestral (Q2 vs Q1-2026)	**+1.31 %**	[-0.72 % a +3.36 %]
Crec. Interanual (Q2-2026 vs Q2-2025)	**+3.48 %**	[+1.41 % a +5.57 %]

Se estima un crecimiento intertrimestral del **+1.31 %** y un crecimiento interanual del **+3.48 %** para el Q2-2026.

Estimaciones y Resultados

Pronóstico para el Segundo Trimestre de 2026 (Q2)

Proyección del modelo MF-BVAR para el trimestre evaluado:

Métrica / Indicador	**Mediana BVAR**	**Intervalo de Credibilidad (95 %)**
PIB real (niveles, MM)	**262,181.0**	[256,930.0 a 267,471.0]
Crec. Intertrimestral (Q2 vs Q1-2026)	**+1.31 %**	[-0.72 % a +3.36 %]
Crec. Interanual (Q2-2026 vs Q2-2025)	**+3.48 %**	[+1.41 % a +5.57 %]

Se estima un crecimiento intertrimestral del **+1.31 %** y un crecimiento interanual del **+3.48 %** para el Q2-2026.

Estimaciones y Resultados

Pronóstico del PIB Mensual Latente (Abril-Junio 2026)

Desagregación del pronóstico trimestral en sus componentes mensuales latentes estimados por el Filtro de Kalman:

Mes Proyectado	Mediana BVAR	Límite Inf (95 %)	Límite Sup (95 %)
Abril 2026	**86,458.1**	84,950.0	87,950.0
Mayo 2026	**86,862.3**	85,050.0	88,600.0
Junio 2026	**88,860.6**	86,930.0	90,921.0

La suma de estos tres meses resulta en la estimación del trimestre agregado (262,181.0), validando la restricción de medición del modelo.

Estimaciones y Resultados

Pronóstico del PIB Mensual Latente (Abril-Junio 2026)

Desagregación del pronóstico trimestral en sus componentes mensuales latentes estimados por el Filtro de Kalman:

Mes Proyectado	Mediana BVAR	Límite Inf (95 %)	Límite Sup (95 %)
Abril 2026	**86,458.1**	84,950.0	87,950.0
Mayo 2026	**86,862.3**	85,050.0	88,600.0
Junio 2026	**88,860.6**	86,930.0	90,921.0

La suma de estos tres meses resulta en la estimación del trimestre agregado (262,181.0), validando la restricción de medición del modelo.

Estimaciones y Resultados

Pronóstico del PIB Mensual Latente (Abril-Junio 2026)

Desagregación del pronóstico trimestral en sus componentes mensuales latentes estimados por el Filtro de Kalman:

Mes Proyectado	Mediana BVAR	Límite Inf (95 %)	Límite Sup (95 %)
Abril 2026	**86,458.1**	84,950.0	87,950.0
Mayo 2026	**86,862.3**	85,050.0	88,600.0
Junio 2026	**88,860.6**	86,930.0	90,921.0

La suma de estos tres meses resulta en la estimación del trimestre agregado (262,181.0), validando la restricción de medición del modelo.

Estimaciones y Resultados

Importancia Predictiva de las Variables

Para entender de dónde provienen las mayores ganancias de información en el pronóstico del PIB latente, se calculó la **Descomposición Histórica de la Varianza del Error de Pronóstico (FEVD)** a 12 meses:

Aporte a la varianza predictiva del PIB:

- **Índice de Seguimiento a la Economía (ISE):** 23.06 %
- **Tasa de Intervención (BanRep):** 16.83 %
- **Índice de Confianza del Consumidor (ICC):** 14.45 %

Estimaciones y Resultados

Importancia Predictiva de las Variables

Para entender de dónde provienen las mayores ganancias de información en el pronóstico del PIB latente, se calculó la **Descomposición Histórica de la Varianza del Error de Pronóstico (FEVD)** a 12 meses:

Aporte a la varianza predictiva del PIB:

- **Índice de Seguimiento a la Economía (ISE):** 23.06 %
- **Tasa de Intervención (BanRep):** 16.83 %
- **Índice de Confianza del Consumidor (ICC):** 14.45 %
- **Tasa de Desempleo (TD):** 12.54 %
- **Precio del Petróleo (Brent):** 11.04 %

Estimaciones y Resultados

Importancia Predictiva de las Variables

Para entender de dónde provienen las mayores ganancias de información en el pronóstico del PIB latente, se calculó la **Descomposición Histórica de la Varianza del Error de Pronóstico (FEVD)** a 12 meses:

Aporte a la varianza predictiva del PIB:

- **Índice de Seguimiento a la Economía (ISE):** 23.06 %
- **Tasa de Intervención (BanRep):** 16.83 %
- **Índice de Confianza del Consumidor (ICC):** 14.45 %
- **Tasa de Desempleo (TD):** 12.54 %
- **Precio del Petróleo (Brent):** 11.04 %

Estimaciones y Resultados

Importancia Predictiva de las Variables

Para entender de dónde provienen las mayores ganancias de información en el pronóstico del PIB latente, se calculó la **Descomposición Histórica de la Varianza del Error de Pronóstico (FEVD)** a 12 meses:

Aporte a la varianza predictiva del PIB:

- **Índice de Seguimiento a la Economía (ISE):** 23.06 %
- **Tasa de Intervención (BanRep):** 16.83 %
- **Índice de Confianza del Consumidor (ICC):** 14.45 %
- **Tasa de Desempleo (TD):** 12.54 %
- **Precio del Petróleo (Brent):** 11.04 %

Estimaciones y Resultados

Importancia Predictiva de las Variables

Para entender de dónde provienen las mayores ganancias de información en el pronóstico del PIB latente, se calculó la **Descomposición Histórica de la Varianza del Error de Pronóstico (FEVD)** a 12 meses:

Aporte a la varianza predictiva del PIB:

- **Índice de Seguimiento a la Economía (ISE):** 23.06 %
- **Tasa de Intervención (BanRep):** 16.83 %
- **Índice de Confianza del Consumidor (ICC):** 14.45 %
- **Tasa de Desempleo (TD):** 12.54 %
- **Precio del Petróleo (Brent):** 11.04 %

Estimaciones y Resultados

Importancia Predictiva de las Variables

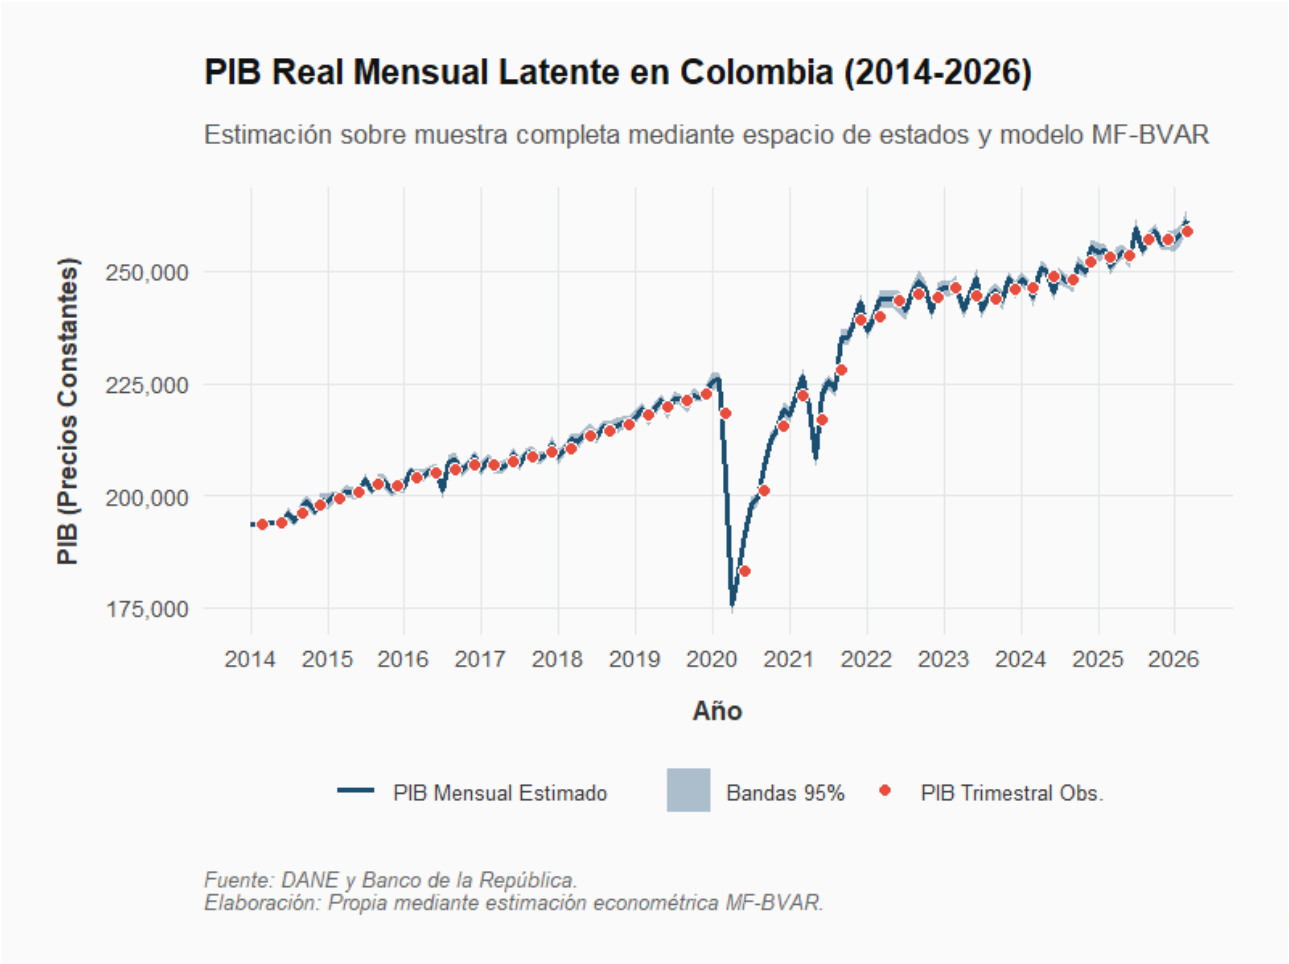
Para entender de dónde provienen las mayores ganancias de información en el pronóstico del PIB latente, se calculó la **Descomposición Histórica de la Varianza del Error de Pronóstico (FEVD)** a 12 meses:

Aporte a la varianza predictiva del PIB:

- **Índice de Seguimiento a la Economía (ISE):** 23.06 %
- **Tasa de Intervención (BanRep):** 16.83 %
- **Índice de Confianza del Consumidor (ICC):** 14.45 %
- **Tasa de Desempleo (TD):** 12.54 %
- **Precio del Petróleo (Brent):** 11.04 %

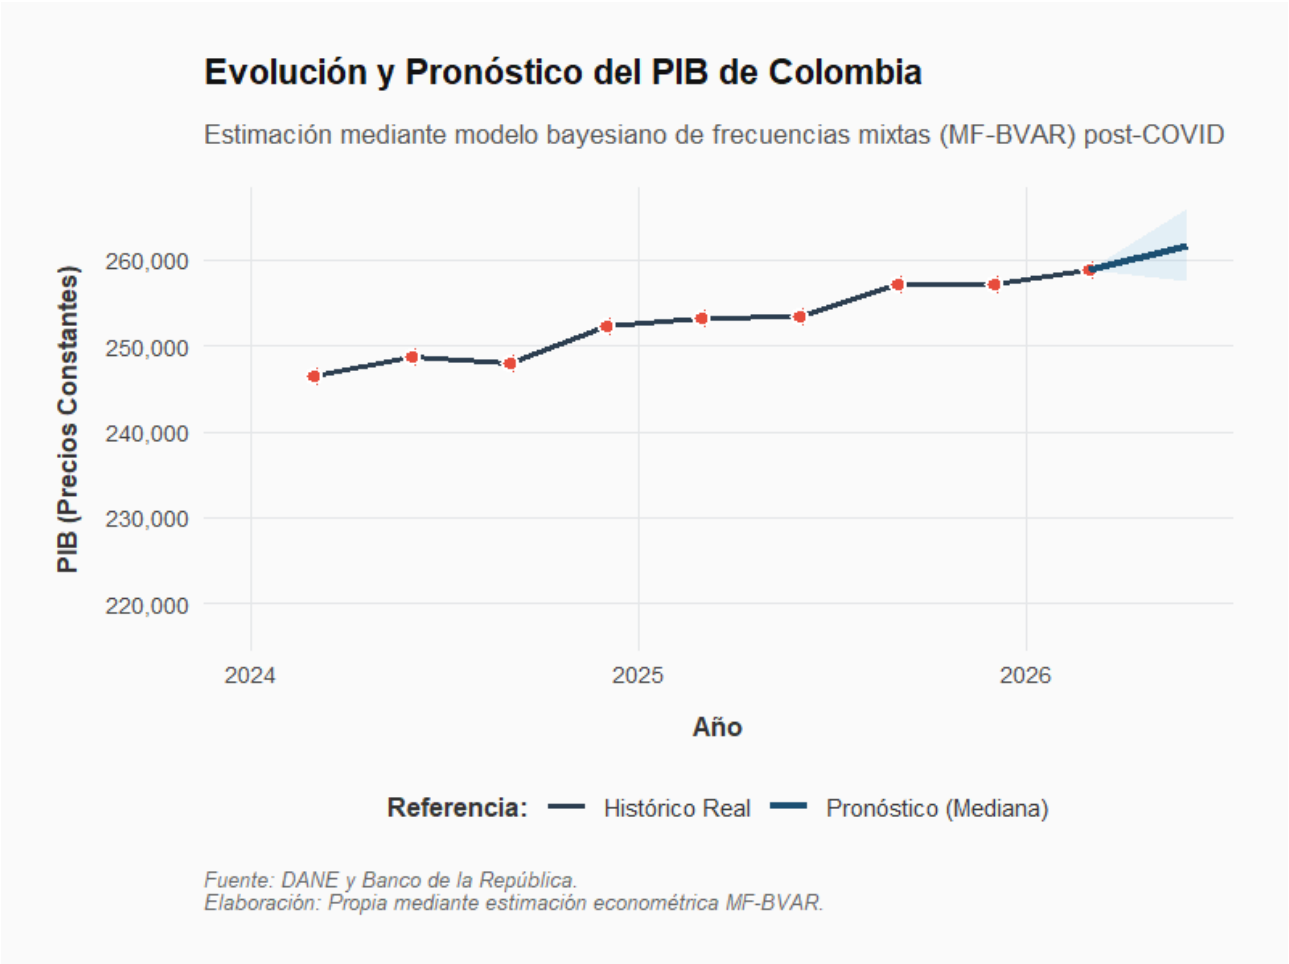
Estimaciones y Resultados

PIB Mensual Latente Completo



Estimaciones y Resultados

Pronóstico Trimestral Q2-2026



Consideraciones finales

- El MF-BVAR permite generar **nowcasts mensuales del PIB colombiano** explotando la información disponible antes de la publicación oficial trimestral del DANE, sin sacrificar la coherencia estadística entre frecuencias.
- El tratamiento del PIB como variable de estado latente —y no como un dato interpolado mecánicamente— permite que la agregación trimestral opere como una restricción de medición exacta dentro del filtro de Kalman.

Consideraciones finales

- El MF-BVAR permite generar **nowcasts mensuales del PIB colombiano** explotando la información disponible antes de la publicación oficial trimestral del DANE, sin sacrificar la coherencia estadística entre frecuencias.
- El tratamiento del PIB como **variable de estado latente** — y no como un dato interpolado mecánicamente — permite que la agregación trimestral opere como una restricción de medición exacta dentro del filtro de Kalman.

Consideraciones finales

- El MF-BVAR permite generar **nowcasts mensuales del PIB colombiano** explotando la información disponible antes de la publicación oficial trimestral del DANE, sin sacrificar la coherencia estadística entre frecuencias.
- El tratamiento del PIB como **variable de estado latente** — y no como un dato interpolado mecánicamente — permite que la agregación trimestral opere como una restricción de medición exacta dentro del filtro de Kalman.

Consideraciones finales

- Las proyecciones revelan un crecimiento esperado interanual del **3.48 %** para el segundo trimestre de 2026, lo que demuestra la utilidad del MF-BVAR para anticipar escenarios económicos con base en información adelantada.
- El enfoque bayesiano (prior de Minnesota + MNIW) resuelve el problema de sobreparametrización inherente a un VAR mensual con múltiples variables y rezagos, permitiendo estimar el sistema incluso con series relativamente cortas.

Consideraciones finales

- Las proyecciones revelan un crecimiento esperado interanual del **3.48 %** para el segundo trimestre de 2026, lo que demuestra la utilidad del MF-BVAR para anticipar escenarios económicos con base en información adelantada.
- El enfoque bayesiano (prior de Minnesota + MNIW) resuelve el problema de sobreparametrización inherente a un VAR mensual con múltiples variables y rezagos, permitiendo estimar el sistema incluso con series relativamente cortas.

Consideraciones finales

- Las proyecciones revelan un crecimiento esperado interanual del **3.48 %** para el segundo trimestre de 2026, lo que demuestra la utilidad del MF-BVAR para anticipar escenarios económicos con base en información adelantada.
- El enfoque bayesiano (prior de Minnesota + MNIW) resuelve el problema de sobreparametrización inherente a un VAR mensual con múltiples variables y rezagos, permitiendo estimar el sistema incluso con series relativamente cortas.

MUCHAS GRACIAS...!